



DATAN MALLINTAMISEN MERKITYS BI-OHJELMISTOILLA

Lappeenrannan–Lahden teknillinen yliopisto LUT

Tuotantotalouden koulutusohjelma

2022

Tekijä Samu Lahdenperä

Tarkastajat: Dosentti Kalle Elfvengren

Tutkijatohtori Lasse Metso

TIIVISTELMÄ

Lappeenrannan–Lahden teknillinen yliopisto LUT

Teknis-luonnontieteellinen

Tuotantotalous

Samu Lahdenperä

DATAN MALLINTAMISEN MERKITYS BI-OHJELMISTOLLA

Tuotantotalouden Diplomityö

2022

96 sivua, 28 kuvaa, 7 taulukkoa ja 3 liitettä

Tarkastajat: Dosentti Kalle Elfvengren ja Tutkijatohtori Lasse Metso

Avainsanat: tietomallinnus, Power BI, SSAS, Tabular, DAX, business intelligence, BI, analytiikka, raportointi, parhaat käytännöt

Tiedon määrä ja tarve datan analysoinnille globaaleilla markkinoilla jatkaa kasvamistaan. Toimintatapojen kehittäminen ja parhaiden käytäntöjen noudattaminen tiedolla johtamisen kehityksissä jää kuitenkin kehittäjien sekä tuoteomistajien näkökulmasta usein kiireen verukkeella puolitiehen. Tarpeetonta teknistä velkaa aiheuttavat muun muassa sopivien apuvälineiden käytön puute, tarkistuslistojen puute, ajanpuute ja virallistamattomat kehittämissen prosessit, puutteelliset määrittelyt sekä teknisen taustan ymmärryksen puute. Ratkaisemalla edellä mainittuja ongelmia voidaan auttaa ratkaisemaan IT-alan osaajapulaa.

Työn lähtökohtana oli etsiä ratkaisuja teknisten velan ennakoiwaan minimointiin sekä jatkuvan kehittämisen toimintatapojen parantamiseen. Tähän pyrittiin käyttämällä hyödyksi Power BI -ohjelmistoille kehitettyjä apuvälineitä sekä tutustumalla tarkemmin tuotteiden teknologiseen taustaan. Tavoitteena oli saada kerrottua työn lukijalle miksi ongelmia tulisi ratkaista, ja miten niitä voidaan ratkaista.

Tutkimus on jaettu teoria- ja empiriaosuuksiin. Teoriaosuudessa käydään läpi hyödylliset Power BI -pohjaiset teknologiat ja teknologinen tausta, joiden avulla luodaan teoriaviitekehys Power BI -teknologioiden ymmärtämiselle ja niiden optimoinnille. Käytännön työn osuudessa kerrotaan teoriasta löytyviä vastauksia tuotteiden määrittelyihin, jatkuvan kehittämisen toimintatapoihin sekä tukitoimintoihin ja tiedon mallintamiseen liittyvät huomioita tiedolla johtamisen ratkaisujen kehittämisen kannalta.

ABSTRACT

Lappeenranta–Lahti University of Technology LUT

School of Engineering Science

Industrial Engineering and Management

Samu Lahdenperä

IMPORTANCE OF DATA MODELING WITH BUSINESS INTELLIGENCE SOFTWARE

Master's thesis

2022

96 pages, 28 figures, 7 tables and 3 appendices

Examiners: Associate Professor Kalle Elfvengren and Post-doctoral researcher Lasse Metso

Keywords: Data modeling, Power BI, SSAS, Tabular, DAX, Business Intelligence, BI, Analytics, Reporting, Best Practice

The amount of data and need for analyzing it keeps growing on the global markets. However, the development of operating methods and observing the best practices in Business Intelligence development are often halfway from the point of view of developers and product owners under the pretext of urgency. Unnecessary technical debt is caused for example by lack of using suitable tools, lack of checklists, working in the rush, unofficial development projects, inadequate definitions, and lack of understanding of the technical background. By solving the above-mentioned problems can also help to solve the shortage of IT-workers.

The starting point of the work was to find solutions for proactive minimization of technical debt and for the improvement of continuous development practices. This was done by utilizing the tools developed for Power BI related software's and by researching the technical background of the products. The aim was to tell the reader why the problems should be solved and how they can be solved.

The research is divided into theoretical and empirical parts. In the theoretical part, useful Power BI based technologies and technological background are reviewed, which help to create a theoretical reference framework for understanding and optimizing Power BI Technologies. The practical part of the work describes the answers found in the theory to the definitions of product, the methods of continuous improvement, as well as the support functions and data modeling in terms of development of Business Intelligence Solutions.

KIITOKSET

Kiitokset tuella ja tsempillä mukaan työhön henkisellä tasolla osallistuneille. Kiitos työn myös työn ohjaajille tsempestä.

Samu Lahdenperä

Helsinki

Lyhenteet

AS	Analysis Services
BI	Business Intelligence
C#	C sharp
DAX	Data Analysis Expressions
DMV	Dynamic Management View
ETL	Extract Transform Load
ID	Identification Document
IT	Information Technology
JSON	JavaScript Object Notation
KPI	Key Performance Indicator
RAM	Random-access memory
RLE	Run Length Encoding
SQL	Structured Query Language
SSAS	SQL Server Analysis Services
TOM	Tabular Object Model
VertiPaq	xVelocity in-memory analytical engine

Sisällysluettelo

Tiivistelmä

Abstract

Kiitokset

Symboli- ja lyhenneluettelo

1.	Johdanto.....	10
1.1.	Työn tausta	10
1.2.	Tavoitteet, tutkimuskysymykset ja rajaukset	11
1.3.	Tutkimusmenetelmät ja työn rakenne	12
2.	Power BI.....	15
2.1.	Mikä Power BI on?	15
2.2.	Power BI Desktop	17
2.3.	Power BI Service.....	22
2.4.	Data Analysis Expressions	23
2.5.	SQL Server Analysis Services (SSAS) Tabular-malli	26
2.6.	VertiPaq-moottori	29
3.	Datan mallinnus ja parhaat käytännöt	36
3.1.	Tähtimalli	36
3.2.	Lumihiutalemalli	38
3.3.	Header- ja detail-tilut.....	40
3.4.	Useamman faktataulun käyttö.....	41
3.5.	Nimeämiskäytännöt.....	44
3.6.	Mallintamisen parhaat käytännöt	47
4.	Mallintamisen apuvälineet.....	50
4.1.	Tabular Editor	50
4.2.	VertiPaq Analyzer	53
4.3.	DAX Studio.....	55
4.4.	Ohjelmoinnin katselmointi.....	56
5.	Mallintaminen.....	59
5.1.	Tehtyjen tietomallien kehitystyöt.....	59

5.2.	Uusien raportti- ja tietomallikokonaisuuksien määrittely	63
5.3.	Uusien tietomallien kehittäminen	66
5.4.	Apuvälineiden käyttäminen	69
5.5.	Teknisen velan vähentämisen tukitoiminnot mallintamisessa	71
6.	Yhteenveto ja johtopäätökset	74
6.1.	Yhteenveto	74
6.2.	Johtopäätökset	79
	Lähteet	81

Liitteet:

Liite 1. Azure Analytics Services hinnasto 2.12.2021

Liite 2. Parhaiden käytäntöjen tarkemmat kuvaukset avoimesta Microsoftin datasetistä

Liite 3. Power BI Embedded hinnasto 16.2.2022

Kuvaluettelo

Kuva 1. Tutkimuksessa käytetyt hakusanat, rajaukset ja tietokannat

Kuva 2. Diplomityön rakenne

Kuva 3. Gartnerin BI-tuotteiden arvostelun vertailu tammikuun 2019 ja tammikuun 2020 väliltä (Climber, 2020)

Kuva 4. Power BI Desktopin kolme näkymää

Kuva 5. Power BI Desktopin kolme ruutua

Kuva 6. Esimerkki Fields-kentän laskureista ja taulukoista

Kuva 7. Power Query editoriin pääseminen

Kuva 8. Power BI Desktopin Power Query näkymä osineen

Kuva 9. Tietokantataulun sisällön esimerkki (Wilson, 2017, s.20)

Kuva 10. Esimerkki luodusta relaatiosta (Wilson, 2017, s.22)

Kuva 11. Russon ja Ferrarin (2015, s.404) esimerkkiä mukaileva numeraalisten arvojen enkoodauksen toimintatapa

Kuva 12. Russon ja Ferrarin (2015, s.405) esimerkkiä mukaileva sanakirjastojen enkoodauksen toimintatapa

Kuva 13. Russon ja Ferrarin (2015, s.407) esimerkkiä mukaileva RLE-pakkauksen toimintatapa

Kuva 14. Russon ja Ferrarin (2015, s.408) esimerkkiä mukaileva sanakirjastojen enkoodauksen ja RLE-pakkauksen yhdistetty toimintatapa

Kuva 15. Esimerkkirakenne tähtimallista. * kuvaa vierasavainta ja 1 pääavainta

Kuva 16. Esimerkki lumihiihtalemallin tauluista ja niiden yhteyksistä

Kuva 17. Russon ja Ferrarin (2017 s.30) Kirjan mallia mukaileva header- ja detailtaulun yhteys. PK = PrimaryKey, pääavain ja FK = ForeignKey, vierasavain

Kuva 18. Esimerkki ostotaulun ja myyntitaulun yhdistävästä tuotedimensiosta

Kuva 19. Esimerkki kahden faktataulun tietomallista, jossa dimensiot ovat yhdistettyjä toisiinsa

Kuva 20. Useampaa faktataulua käyttäessä voidaan suodattaa visualisointeja

Kuva 21. GitHubin BPARules.json -tiedoston parhaat käytännöt analysoituna

Kuva 22. Esimerkki lausekkeesta ja korjauslausekkeesta nimittäin ja kategorioittain

Kuva 23. Parhaiden käytäntöjen laskennallisten tasojen mainintakerrat

Kuva 24. Tabular Editor 2.16.4 käyttöliittymä

Kuva 25. VertiPaq Analyzerin käyttöliittymä ja datasisältö

Kuva 26. Esimerkki Tabular Editorissa muotoillusta DAX-koodista

Kuva 27. Esimerkki Tabular Editorin automaattisista tietomallin korjauksista

Kuva 28. DAX Studion VertiPaq Analyzerin kooste tietomallista

Taulukkoluetelo

Taulukko 1. DAX-funktioiden kategoriat ja selitykset (Duncan, Sharkley & Kinsman, 2021)

Taulukko 2. Esimerkkejä tietokannan taulujen nimeämiskäytännöistä

Taulukko 3. Tietomallin taulujen suositellut nimeämissäännöt (Ferrari & Russo, 2017)

Taulukko 4. VertiPaq Analyzerin Tables-välilehden sarakkeiden selitteitä. Kaikki koot ovat bittejä (B)

Taulukko 5. DAX Studion verkkosivuilta löytyvät ominaisuudet

Taulukko 6. Microsoftin esimerkit kerättävistä raporttivaatimuksista (Microsoft, 2022c)

Taulukko 7. Microsoftin esimerkit selvitettävistä tietovaatimuksista (Microsoft, 2022c)

1. Johdanto

Tutkimuksen kohteena ovat Power BI - ja SSAS-tietomallit, niihin liittyvät parhaat käytännöt, datan mallintamiseen liittyvät kokonaisuudet ja niiden toteuttamiseen tarvittavat apuvälineet sekä toimintatavat.

1.1. Työn tausta

Diplomityössä käydään läpi Power BI - ja Tabular-mallien ominaisuuksia mallintamisen kannalta, mallintamiseen liittyviä teorioita ja käytäntöjä, sekä apuvälineitä näiden toteuttamisen kannalta. Työssä perustellaan miksi edellä mainittuja sisältökokonaisuuksia sekä apuvälineitä kannattaisi käyttää olemassa olevien tietomallien parantamiseen, optimointiin sekä suunnitteilla olevien tietomallien ja raporttien kehittämiseen. Työn tarkoituksena on helpottaa kehittäjiä ja organisaatioita teknisen velan vähentämisessä, sekä auttaa lukijaansa ymmärtämään miksi teknisen velan vähentäminen datan mallinnuksessa on olennaista.

Gartnerin (2021) mukaan IT-palveluiden kasvun on arvioitu nousevan vuoden 2020 luvuista vuoteen 2021 mennessä 11.2 % ja vuodesta 2021 vuoteen 2022 mennessä 8.6 %. Samanlaisesti tilastopalveluja tuottavan Statistan von See (2021) arvioi, että luodun, kaapatun, kopioidun ja käytetyn datan määrä tulee kasvamaan vuoden 2020 arvioidusta 64.2 triljoonasta gigatavusta vuoteen 2025 mennessä yli 180 triljoonaan gigatavuun. IT-palvelujen ja datan volyymin kasvusta voidaan olettaa, että Business Intelligence (BI) -alan kysyntä tulee kasvaamaan jatkossakin. Tämän perusteella voidaan myös olettaa, että tietovarastojen, analyysiratkaisujen ja tietomallien parhaiden käytäntöjen koostamiselle on tarvetta nyt ja tulevaisuudessa. Datan määrän lähes kolminkertaisen kasvun ja IT- sekä data-alan työvoimapulan vuoksi (ManpowerGroup, 2021) työtehtävien järkevöittämisestä voidaan pitää välttämättömänä vastatakseen osaajapulan ja datan kasvun aiheuttamiin kysyntä- ja tarjontaongelmiin.

Diplomityön tekijä ei löytänyt suomenkielistä kirjallista kokonaisuutta joka olisi käsitellyt työn mukaista datan mallintamiseen liittyvää aihetta Power BI – ja Tabular-mallien kohdalla, vaikka visualisointeja, raportointia ja Power BI -ohjelmistoja hyväksi käyttäviä KPI-mittareiden luontia käsitteleviä kokonaisuuksia löytyi useampi. Aihe on työn kirjoittajalle kiinnostava diplomityön alan seitsemän vuoden työkokemuksen takia. Puuttuvasta aiheesta

käsittelyä materiaalista johtuen on kohtuullista olettaa diplomityön käsittelevän ajankoh-
taista sekä tarpeellista aihetta.

1.2. Tavoitteet, tutkimuskysymykset ja rajaukset

Tutkimuksen tavoitteena on tutkia mallintamiseen liittyviä teknologioita ja toimintatapoja, sekä etsiä niitä tukevia apuvälineitä Power BI - ja SSAS (Sql Server Analysis Services) -teknologioilla tehtäviin tietomalleihin. Diplomityön keskeisin tavoite on löytää toimivia työvälineitä ja keinoja teknisen velan vähentämiseen tietomallinnuksessa. Teknisen velan vähentämisellä on tarkoitus vastata osajapulan sekä alan kysynnän kasvun aiheuttamiin mahdollisiin ongelmiin. Työn tavoitteena on tarkastella aihekokonaisuutta olemassa olevien tietomallien optimoinnin ja parantamisen kannalta, sekä tulevien kehitettävien ja uusien tietomallinnus- sekä raportointiprojektien kannalta. Tutkimuksen avulla on tarkoitus löytää vastaukset seuraaviin tutkimuskysymyksiin:

Tutkimuskysymykset:

1. Mitä teknologioita ja parhaita käytäntöjä löytyy Power BI - ja Tabular-malleihin liittyen?
2. Miksi ja miten parhaita käytäntöjä pitäisi implementoida olemassa oleviin ja tuleviin tietomalleihin?
3. Minkälaiset tukitoiminnot avustavat parhaiden käytäntöjen implementointia, noudattamista ja teknisen velan vähentämistä?


Työssä käsitellään Power BI - ja SSAS-pohjaisia tietomalleja, tarkemmin katsottuna VertiPaq (xVelocity in-memory analytical engine) -moottorilla toimivia tietomalleja. Osana työtä on tietomallien kehittämisessä sekä mallinnuksessa käytettävät parhaat käytännöt, toimintatavat sekä näiden toteuttamisessa auttavat apuohjelmat. Kirjallisuustutkimuksen teoriaosuus on rajattu sisältämään valitut teknologiat, niiden kuvaukset, datan mallinnukseen liittyviä tärkeitä kokonaisuuksia ja parhaita käytäntöjä. Tutkimuksessa perehdytään tarkemmin siihen, minkälaisen kokonaisuuden edellä mainitut asiat muodostavat. Diplomityössä vastataan tutkimuksessa esitettyihin kysymyksiin. Tutkimuksen lopputuloksena on organisaatioille käytettäväksi tarkoitettu toimenpide- ja apuvälinekokonaisuus Power BI - ja Tabular-

mallinukseen liittyvään kokonaisuuteen. Toimenpide- ja apuvälinekokonaisuus pyrkii auttamaan teknisen velan minimoinnissa ja vähentämisessä. Työn lopputuloksilla on tarkoitus auttaa lukijaansa ymmärtämään, miksi BI-ohjelmistoilla tapahtuvaa toimintatapojen kehittämistä kannattaa tehdä.

Työstä on rajattu pois tietomallien partitiointiin ja päivityksiin liittyvät tehtävät, suuremmat arkkitehtuurilliset kysymykset, pois lukien tietomallien käytön erikseen ylös nostetut mahdollisuudet. Diplomityöstä ei käsitellä visualisointien ja datan sisällöllistä näkökulmaa eikä tarkempien ohjeiden tekemistä apuohjelmia ja valittuja teknologioita varten.

1.3. Tutkimusmenetelmät ja työn rakenne

Tutkimuksen empiirinen osio on toteutettu hyödyntäen kvalitatiivisia menetelmiä. Tutkimuskysymyksiin haetaan vastaukset kirjallisuustutkimuksella sekä diplomityön tekijän aikaisemman alan osaamisen perusteella. Lähteinä käytetään paljon verkosta löytyvää materiaalia niiden ajankohtaisuuden takia. Power BI päivittyy kuukauden sykleissä, mistä johtuen materiaali on aina haettava uudesta ajantasaisesta tiedosta johon kirjojen ja muiden lähteiden julkaisusykli eivät kykene vastaamaan. Lisäksi tutkimus- ja lähdemateriaaliksi on valikoitu alalla hyvänä pidettyjä kirjallisia kokonaisuuksia, yksittäisiin aihealueisiin liittyvää verkkokirjallisuutta ja artikkeleja. Kuvassa 1 on esitetty verkkokirjallisuuteen ja verkkohakuun liittyneitä tietokantoja, hakusanoja ja hakurajauksia.




Kuva 1. Tutkimuksessa käytetyt hakusanat, rajaukset ja tietokannat

Diplomityö koostuu neljästä eri osasta. Ensimmäisessä osassa käydään läpi mikä Power BI on ja mitä muita teknologioita Power BI:n taustaan ja alaisuuteen liittyy, sekä mitä käyttömahdollisuuksia kyseisellä työvälineellä on mallintamisen kannalta. Power BI -osiossa luodaan tausta teknologisten tarpeiden ymmärtämiselle.

Toisessa osassa käsitellään datan mallintamiseen ja parhaisiin käytäntöihin liittyviä kokonaisuuksia. Kokonaisuudessa käsitellään Power BI:hin ja sen teknologiseen taustaan liittyviä aihioita ja toimintatapoja, joita ymmärtämällä mahdollistetaan parempi teknisen velan minimointi.

Kolmannessa osassa käydään läpi mallintamisen apuvälineitä ja toimintatapoja. Osa pitää sisällään Power BI - ja Tabular-mallien kehitystä parantavia ja helpottavia apuvälineitä sekä kehittämistä tukevia teknologioista. Valitut apuvälineet liittyvät teknologioihin ja mallintamiseen sekä kehitystyön päivittäiseen tekemiseen. Mallintamisen apuvälineet -osiossa tuodaan ilmi mihin apuvälineitä voidaan käyttää, ja mitä ne ovat.

Neljännessä osassa eli mallintamisessa käydään läpi kuinka teoriaosuudessa käsitellyt aiheita ja aihekokonaisuuksia voidaan hyödyntää työskentelyn kehittämisessä. Aihekokonaisuuksia käsitellään olemassa olevien tietomallien, uusienkin tietomallien, määrittelyjen, apuvälineiden ja tukitoimintojen kannalta. Käsiteltävän aiheet nivotaan yhtenäiseksi kokonaisuudeksi yhteenvedossa. Mallintamisen osio ei pidä sisällään tarkkoja ohjeita siitä miten kyseisiä apuvälineitä käytetään. Diplomityön tarkempi rakenne tulee ilmi kuvasta 2.



Kuva 2. Diplomityön rakenne

Teoriaan kuuluvia lukuja ovat luvut 2, 3 ja 4. Luku 5 on työn varsinainen työ- ja tutkimusosuus. Lopputulokset tuodaan esiin luvun 6 sisällä yhteenvedon ja johtopäätöksen kappaleissa. Työssä peilataan aiheita edellisiin kappaleisiin ja lukuihin.

2. Power BI

Tässä luvussa käydään läpi Power BI -työvälineen keskeisimpiä ominaisuuksia tietomallintamisen osalta. Kappaleet muodostavat kokonaisuuden, joka auttaa lukijaa ymmärtämään Power BI:n ja sen taustalla olevien teknologioiden merkityksen datan mallintamisessa.

2.1. Mikä Power BI on?

Power BI on Microsoftin 2015 julkaisema tiedolla johtamisen työväline. Power BI on useasta erillisestä työvälineestä koostuva kokoelma ohjelmistopalveluja. Power BI -kokonaisuuden avulla data voidaan muuttaa tietomalleiksi ja visualisoinneiksi. Power BI Servicessä tietomallit ja visualisoinnit voidaan jakaa loppukäyttäjää varten samalla mahdollistaen itsepalveluraportoinnin ja tietomallien jakamisen. Power BI:n kolme perusosaa ovat Power BI Desktop, Power BI Service ja Power BI -mobiilisovellukset. Power BI:n avulla voidaan yhdistää dataa jopa sadoista eri tietolähteistä (Ulagaratchagan, 2021). Tietolähteinä voidaan käyttää useita eri tietokantoja ja lähdejärjestelmiä kuten esimerkiksi Microsoftin, Snowflaken ja Oraclen tuotteita. Tietolähteenä on mahdollista käyttää myös Excel-tiedostoja. Power BI:tä voidaan pitää itsepalveluraportointivälineenä ja tietomallipohjaisena BI-ratkaisuna (Russo 2018).

Microsoft ja Power BI ovat vakiinnuttanut johtoasemansa analytiikka- ja raportointivälineiden kärjessä. Gartner on valinnut Microsoftin ja Power BI:n johtajaksi ja parhaimmaksi tulevaisuuden vision ja toimintakyvyn suhteen viimeisen kolmen vuoden ajan. Viimeisimmässä Gartnerin teettämässä mutta Climberin julkaisemassa tarkastelussa (kuva 3) Microsoftin asema alansa johtajana on kasvanut.

Magic Quadrant for Analytics and Business Intelligence Platforms.



Kuva 3. Gartnerin BI-tuotteiden arvostelun vertailu tammikuun 2019 ja tammikuun 2020 väliltä (Climber, 2020)

Kokonaisuudessaan Microsoftin BI-tuotteet ovat olleet 14 vuotta putkeen alansa johtajia. Ulagaratchaganin (2021) mukaan kymmenen suurinta syytä miksi asiakkaat valitsevat Power BI:n ovat seuraavat:

1. Merkityksellisten tietojen luominen automaattisesti Power BI:llä, integrointi Exceliin ja Microsoft Teams -sovellukseen
2. Datat yhdistäminen satoihin eri tietolähdetyyppeihin Power Queryn avulla
3. Älykkäiden järjestelmien rakentaminen nopeasti Power BI:n ja Azure Synapse Analytics avulla
4. Helppo siirtyminen merkityksellisistä tiedoista toimintaan Microsoft Power Platformin avulla
5. Ainoa BI-tuote jossa on sisäänrakennettu tietojen katoamisen esto Microsoftin data-suojauksen ja Microsoft Cloud App -suojausten kautta
6. Alan johtava tekoäly auttaa löytämään vastaukset kysymyksiin datasta helposti
7. Kategoriansa parhaimmat mobiilikokemukset Power BI Mobilen avulla
8. Pilvimaturiteetti pohjautuu yhteen suurimmista ja nopeammista kasvavaan BI pilviin

9. Nopea käyttäjäohjautuva innovaatio, uusia toiminnallisuuksia julkaistaan viikoittain käyttäjäpalautteen perusteella
10. Hinnoittelu, joka sallii datakulttuurin mukaan pääsyn koko organisaatiotasolle.


Power BI:llä toteutettavia sovelluksia voidaan ajatella tietomallimallipohjaisina visualisoidavissa olevina ratkaisuin, sillä Power BI:n tietomallinnus kiteytyy tarkasti jo vuosia olemassa olleeseen SSAS (SQL Server Analysis Services) -teknologiaan sekä DAX (Data Analytic Expressions) -kieleen.

2.2. Power BI Desktop

Power BI Desktop on tietokoneelle ladattava kuukausittain päivittyvä ohjelmisto, jolla voidaan luoda yhteys tietolähteisiin ja rakentaa tietomalleihin pohjautuvia visualisointeja, sekä jakaa näitä Power BI Service -palveluun. Power BI Desktopin avulla saadaan luotua yhteisiä datan lukua helpottavia sekä nopeuttavia visualisointeja. Useimmiten Power BI Desktopilla rakennetut valmiit ratkaisut jaetaan Power BI Service -palveluun, jossa raportteja ja tietomalleja päästään tarkastelemaan valittujen käyttäjäryhmien sisällä. Power BI Desktopin yleisimmät käyttötavat ovat seuraavat: (Iseminger, 2021)


1. Tietoihin yhdistäminen
2. Tietojen muuntaminen ja puhdistaminen sekä tietomallin luominen
3. Kaavioiden ja muiden visualisointien luominen – tiedot esitetään Power BI Desktopissa visuaalisessa muodossa
4. Raporttien luominen – visualisoinnit kootaan yhdelle tai useammalle raporttisivulle
5. Raporttien jakaminen muiden kanssa Power BI -palvelun avulla.

Power BI Desktopissa tehdyt laskennat tapahtuvat DAX-kielellä, jolla saadaan laskettua datasta tärkeät tiedot määritysten vaatimalla tavalla. Visualisointien lisäksi raporteille on mahdollista asettaa rivitasen rajauksia erikseen määritetyille käyttäjäryhmille, jolloin data ei päädy väärin käsiin. Samalla sovelluksessa on mahdollista määrittää organisaatioiden visuaalisen ilmeen mukaiset tyyliohjeet. Sovelluksen toimintaperiaate koostuu kolmesta eri näkymästä (kuva 4), jotka ovat Raportti, Tiedot ja Malli.




Kuva 4. Power BI Desktopin kolme näkymää

Raportti-välilehdellä luodaan visualisointeja ja laskureita raporteille. Yksittäinen raportti voi sisältää useamman välilehden, mutta kuitenkin aina vähintään yhden. Ilman visualisointeja verkkoon julkaistu raportti on käytännössä Power BI -tietomalli. Raporttivälilehdellä sijaitsevat Filters- (Suodattimet), Visualizations- (Visualisoinnit) ja Fields- (kentät) ruudut (kuva 5), joissa on mukana nimiänsä vastaavat ominaisuudet.



Kuva 5. Power BI Desktopin kolme ruutua

Filters-ruudussa pääsee tarkastelemaan suodattimia, joiden avulla dataa voidaan suodattaa joko visualisointi-, sivu- tai raporttitasolla. Tämä helpottaa datan tarkastelua esimerkiksi visualisointi-, sivu-, tai aihekohtaisesti. Samalla nopeatkin muutokset olemassa oleviin laskureihin ja laskureita käyttäviin visualisointeihin tulevat mahdollisiksi. Visualizations-ruudussa valitaan visualisointi, jonka avulla data halutaan näyttää. Fields kentässä sijaitsevat tietomallin näkyvissä olevat kentät ja laskurit. Fields-kentässä on mahdollista erotella laskurit muista tauluista ja datasta kuvan 6 tyyliä.




Kuva 6. Esimerkki Fields-kentän laskureista ja taulukoista

Tiedot-välilehdellä voidaan tarkastella ja suodattaa dataa tarkemmin rivitasolla, kuitenkin jättämättä tietoja pois tietomallista. Tätä välilehteä käytetään usein rivitason datan tarkasteluun ja virheiden etsimiseen datasta. Tiedot-välilehdellä on mahdollista luoda laskennallisia sarakkeita (Calculated Column) ja laskureita.

Malli-välilehdellä on mahdollista rakentaa tietomalli luomalla relaatioita sekä tarkastelemaan jo olemassa olevan raportin tietomallia. Olemassa olevan tietomallin tarkastelu kyseisellä välilehdellä voi tulla tarpeelliseksi, kun tietomalliin halutaan tehdä lisäyksiä tai vaihtoehtoisesti tuoda mukaan uusia sarakkeita. Power BI:ssä on oletuksena asennettaessa päällä automaattinen yhteyksien luonti eri tauluista toisiin sarakkeisiin nimien perusteella. Tällöin


yhdistetään esimerkiksi faktataulun AsiakasAvain-kenttä automaattisesti dimensiotaulun AsiakasAvain-kenttään. Semanttista tietomallia tietovarastosta ladatessa yhteydet luodaan automaattisesti, ellei kyseistä ominaisuutta ole otettu pois päältä. Power BI:ssä voidaan käyttää tietolähteenä jo palvelussa olemassa olevia tietomalleja, eli käyttäjäystävällisesti kerrottuna raportteja, jolloin malli välilehti ei ole esillä eikä muokattavissa. Nämä aiemmin kehitetyt ja Power BI Serviceen viedyt tietomallit voivat olla sertifioituja ja vahvistettuja, jolloin mallinnus on ollut mahdollista hoitaa yksiselitteisesti sekä organisaation sääntöjen mukaan. Datan on vahvistettu tällöin olevan käyttökelpoista.

Datan hakeminen tapahtuu Power BI Desktopilla tehtyjen tiedostojen tietomalleihin Power Query-editorin kautta. Power Query-editoriin pääsee käsiksi Home-välilehdeltä Transform Data -kohdasta (kuva 7).



Kuva 7. Power Query editoriin pääseminen

Power Query on graafisen käyttöliittymän sisältävä tietojen muuntamis- ja valmistelumoduuli, jolla voidaan suorittaa tietojen kerääminen, muuntaminen ja lataaminen eli ETL (Extract, Transform, Load) -prosessi (Microsoft, 2021b). Power Queryssä voidaan rikastaa ja muokata dataa liiketoimintatarpeiden mukaisesti, mikäli lähdejärjestelmistä ladattu data ei ole käyttötärpeiden mukaista. Tämänkaltaiset nopeat tietokantataulujen sisältöä käyttötärpeiden mukaan muokkaavat toimenpiteet ovat yleensä välttämättömiä esimerkiksi datan epätäydellisyyden, tietokannassa olevien puuteiden, kehitysjonojen laajuuden ja aikataulutavoitteiden takia. Power Query koostuu viidestä osasta, jotka sijaitsevat kuvassa 8 näytetyistä paikoista.



Kuva 8. Power BI Desktopin Power Query näkymä osineen

Kuvasta 8. ilmenee seuraavat numeroidut kohdat niiden käyttötarkoituksineen: (Microsoft, 2021b)

1. Valintanauha sisältää useita eri vaihtoehtoja välilehtien muunnosten lisäämiseen ja kyselyn vaihtoehtojen valitsemiseen, sekä eri valintanauhan painikkeiden käytön tehtävien suorittamiseen
2. Kyselyt-ruutu näyttää kaikki käytettävissä olevat kyselyt ja niiden avulla mukaan ladatut yksittäiset taulut
3. Nykyinen näkymä kertoo datan sisällön ja näyttää esikatselun tuottamasi kyselyn tiedoista
4. Kyselyasetukset näyttää kaikki vaiheet valitun kyselyn näkymästä ja kyselylle tehdyt toimenpiteet järjestyksessä ylhäältä alas

5. Tilarivi näyttää kyselyäsi koskevia tärkeitä tietoja kuten sarakkeiden määrän sekä mahdollisen käsittelyajan.

Mallinnuksen kannalta nämä muodostavat yhtenäisen kokonaisuuden, joka voidaan myöhemmin rakentaa kokonaiseksi raportiksi ja tietomalliksi laskureineen, relaatioineen, ja rivitason rajauksineen. Power Queryssä tehdään datan valmistelu tietomallinnusta ja laskureiden rakentamista varten käyttökelpoiseen muotoon, ja kokonaisuudessa sitä voidaan ajatella yhtenä osana ETL-prosessia. Power BI Desktopin yleiset käyttötarkoitukset ovat datan muokkaaminen ja tuonti tietomalliin, vaadittavien laskureiden tekeminen, tiedon visualisointi näyttävään, kuvaavaan ja toimivaan muotoon sekä rivitason käyttöoikeusrajausten asettaminen. Varsinainen hallinnollinen puoli ja tarkemmat asetukset sekä jakeluarkkitehtuurin rakentaminen jää tehtäväksi Power BI Service -pilvipalvelun puolella.

2.3. Power BI Service

Power BI Service on kokoelma yhdessä toimivia ohjelmistopalveluja, sovelluksia ja liittimiä, joiden avulla voidaan luoda, jakaa ja hyödyntää merkityksellisiä liiketoimintatietoja mahdollisimman tehokkaasti organisaatioiden kannalta. (Microsoft, 2022b) Power BI Serviceä käytetään pilvipohjaisena raporttien jakelumenetelmänä (Enho, 2021). Power BI Desktopilla toteutetut tietomallit ja raportit voidaan viedä Power BI Serviceen työtiloihin. Työtilat ja työtilojen sisällä olevat tietomallit sekä raportit voidaan jakaa organisaatioiden sisäisesti tai ulkopuolisesti ennalta määrätyille käyttäjille ja käyttäjäryhmille. Kokonaisuudessaan työtilat pitävät sisällään koontinäytöt, raportit, laskentataulukot, tietomallit ja tietovuot. Raportit ja tietomallit toteutetaan usein Power BI desktopilla, mutta niiden toteuttaminen on rajatuin ominaisuuksin mahdollista myös Power BI Servicessä. Power BI Servicen tarjoamat kehitysmahdollisuudet kokonaisuuksiin ovat kuitenkin heikompia Power BI Desktopiin verrattuna. Power BI Servicessä on kuitenkin helppo toteuttaa raporteille pieniä nopeasti julkaistavia muutoksia, kuten esimerkiksi suodattimien asettamisia visualisointeihin. Power BI -työtiloihin viedyt raportit ja koontinäytöt voidaan julkaista laajemmalle yleisölle. Työtilassa ja sovelluksessa olevia raportteja, koontinäyttöjä, tietomalleja, tietolähteitä ja laskentataulukoita voidaan asettaa yhtenäisiksi kokonaisuuksiksi esimerkiksi sisällön perusteella. Sisällöt voidaan määrittää käyttäjäryhmien nähtäväksi jolloin käyttöoikeuksia on helpompi hallita. (Hart, 2021.)

Power BI Servicessä on mahdollista sertifioida sekä ylentää tietojoukkoja, tietovuota, raportteja ja sovelluksia. Ylentämisellä tarkoitetaan suunnitelmallista datan tai kokonaisuuk-sien esiin tuontia koko organisaatiotasolle, jolla kyetään helpottamaan itsepalvelu BI-rapor-tointia nostamalla valittu sisältö ylös. Samanlaisen ylösnoston mutta korkeammalla tasolla tekee sertifiointi. Sertifioinnilla tarkoitetaan sitä, että sisältö vastaa organisaation määäämiä laatustandardeja ja sitä voidaan pitää luotettavana ja virallisena tietolähteenä, joka on valmis käytettäväksi koko organisaation laajuudella (Inbar, 2021). Sertifioinnin avulla voidaan tuoda esiin organisaation tarkasti hallinnoimat ja hyväksymät tietomallit. Esiin voidaan tuoda sovellukset ja raportit jotka ovat rakennettu sääntöjen mukaisesti, ja jotka soveltuvat kaikkien käyttöön. Tietojoukkojen sertifiointi ja ylentäminen mahdollistaa yksittäisen tieto-mallin sisällön vahvistamisen oikeaksi. Data voidaan tällöin vahvistaa yksiselitteiseksi. Tie-tomalleja voidaan käyttää tällöin uudelleen, jolloin datan moniulotteisuus vähenee ja yksit-täiset oikeiksi todetut tiedot sijaitsevat yhdessä paikassa. Rivitason suojaukset ja käyttäjära-jaukset estävät samalla datan väärinkäytön. Samalla voidaan erottaa datan mallinnus ja ra-portin rakentaminen toisistaan, kun tietomallia ja raportteja voivat kehittää eri henkilöt. Tämä minimoi useisiin tietomalleihin tallennettujen tietojen päällekkäisyyden, kun laskurit, mallit ja sarakkeet pysyvät kaikille organisaatioiden käyttäjille samanlaisina ja samannimi-sinä. Tällöin samoja asioita tarkoittaville asioille löydy useita eri selityksiä. Sertifiointi ja ylentäminen tekevät Power BI Servicen käytöstä Power BI:lle ja Excelille samankaltaisen kuin mihin SSAS Tabular-mallia käytetty aiemmin. Tämän vuoksi on hyvä miettiä pienem-piä tietomalleja ja datamääriä varten, voisiko Power BI Servicen käyttö olla hyvä vaihtoehto, mikäli SSAS Tabular-malleja ei ole tarpeellista rakentaa kaikille tietomalleille. Tietomallien käyttö on mahdollista eri työtilojen välillä, jolloin raportteja voidaan rakentaa samoista tie-tomalleista useisiin eri työtiloihin ja eri käyttötärpeisiin yksillä vahvistetuilla luvuilla. Tä-mänkaltainen toimintamalli vahvistaa yritysten itsepalveluraportointikulttuuria, sekä auttaa kehittämään organisaatioiden datanlukutaitoja. Tietomallien uudelleenkäyttö vaatii kuiten-kin tarkkaa suunnittelua ja hallinnointia, jolloin loppukäyttäjien ei ole mahdollista saada tie-tomallista ulos virheellisiä lukuja.

2.4. Data Analysis Expressions

Data Analysis Expressions (DAX) on laskenta- ja kyselykieli, joka on alun perin luotu Mic-rosoftin SQL Server Analysis Services (SSAS) ja Power Pivot For Excel 2010 -tuotteita

varten. DAX on Excelin kaavoja muistuttava kieli. DAX-kielessä voidaan Excelin taulukkomaisesta laskentatavasta poiketen luoda yhteys kokonaiseen jo aiemmin rakennettuun SSAS-tietomalliin, joka mahdollistaa relaatioiden ja laskurien luomisen nopeammin. Samalla mahdollistuu uuden ohjaavan dimensioidatan nopea mukaan tuonti. Viittaukset muihin laskureihin ovat DAX:ssa mahdollisia ja suositeltavia. Viittaukset olemassa oleviin laskureihin minimoivat päällekkäisyyksiä ja parantavat tietomallin ylläpidettävyyttä. Marco Russon ja Alberto Ferrarin (2015, s. 1) mukaan DAX-kieltä voi oppia käyttämään perustasolla nopeasti jopa tunneissa mutta kun kyseeseen tulee rivi- ja kontekstitason arviointiin ja ymmärtämiseen siirtyminen, sekä laskennan tekemät iteraatiot, tulee DAX-kielen ymmärtäminen vaikuttamaan aluksi hankalalta. Sisältökokonaisuuksien ymmärtämisen jälkeen voidaan huomata DAX:n olevan hankalimmissa laskukaavoissa hyvinkin helppo ja loogisesti toimiva kieli. DAXia voidaan verrata SQL (Structured Query Language) kyselykieleen mutta suurin erottava toiminnallinen tekijä on se, että DAX:n pohjalla toimiva moottori ei koskaan käytä vieraiden kenttien avaimia kyselyissään, ellei näin määritellä erikseen (Russo & Ferrari, 2015, s.9). DAX:ia kuitenkin käytetään harvoin SQL:n tapaan kyselykielenä, sillä käyttötarkoitukset ovat usein laskennan puolella ja kyselykielenä Power BI:ssä toimii M-kieli.

DAX:n avulla voi tehdä laskureita (Measure) ja laskennallisia sarakkeita (Calculated Column) seitsemälle eri numeeriselle datatyypille (Russo & Ferrari, 2015, s.18):

1. Kokonaisluku (Integer)
2. Desimaaliluku (Float)
3. Valuutta (Ennalta määriteltä desimaaliluku, joka tallennetaan kokonaislukuna)
4. Aika (DateTime)
5. Boolean (True/False)
6. Teksti (String)
7. Binäärinen suuri objekti (BLOB)

DAX-kieli perustuu Excelin tapaan erilaisiin funktioihin. Funktiot palauttavat sarakkeista ja valituista riveistä määritellyn kontekstitason mukaisen lopputuloksen. Erilaisia analytiikkaan perustuvia funktiota on olemassa yli 250 kappaletta. Funktioiden kategoriat ja niiden tarkemmat selitteet löytyvät taulukosta 1.

Taulukko 1. DAX-funktioiden kategoriat ja selitykset (Duncan, Sharkley & Kinsman, 2021)

Funktion kategoria	Selite
1. Uudet DAX-funktiot	Uusia tai viime aikoina huomattavasti päivitettyjä funktioita. Nämä funktiot ovat uusia tai olemassa olevia funktioita, joita on päivitetty huomattavasti viime aikoina.
2. Koostamisfunktiot	Laskevat skalaariarvon kuten rivien määrän, rivien summan, rivien keskiarvon, minimin tai enimmäisarvon.
3. Päivämäärä- ja aika-funktiot	Microsoft Exceliä muistuttavia päivämäärä- ja aikafunktioita. Perustuvat SQL-serverin käyttämiin datatype tietotyyppeihin.
4. Suodatinfunktiot	Palauttavat tietyt tietotyypit tai etsivät arvoja taulukoista ja suodattavat niitä arvojen mukaan. Hakufunktiot käyttävät taulukoita ja niiden välisiä relaatioita. Suodatusfunktion avulla voidaan käsitellä tietokontekstia ja luoda dynaamisia laskutoimituksia.
5. Talousfunktiot	Käytetään taloudellisia laskelmia suorittavissa kaavoissa, kuten korkokannan tai nettoarvon laskussa.
6. Tietofunktiot	Nämä funktiot näyttävät argumenttina toiselle funktiolle annettua taulukkoa tai saraketta ja palauttavat, vastaako arvo odotettua tyyppiä. Esimerkiksi ISERROR-funktio palauttaa arvon TRUE, jos viitattava arvo sisältää virheen.
7. Loogiset funktiot	Palauttavat tietoja lausekkeiden arvoista. Esimerkiksi TRUE() funktio kertoo onko palauttava lausekkeen arvo totta.
8. Matemaattiset funktiot	Excelin tyyppisiä matemaattisia ja trigonometrisiä funktioita.
9. Muut funktiot	Funktiot, joita ei kyetä luokittelemaan muihin luokkiin
10. Pää- ja alielementtifunktiot	Käytetään tietomallien pää- ja alitason hierarkiana esitettyjen tietojen hallitsemiseen.
11. Suhdefunktiot	Käytetään taulukkojen välisten suhteiden hallintaan ja käyttöön. Voidaan määrittellä esimerkiksi inaktiivinen relaatio aktiiviseksi, jota voidaan käyttää laskennassa.
12. Tilastolliset funktiot	Laskevat tilastollisen jakauman ja todennäköisyyden. Kertovat esimerkiksi keskihajonnan ja permutaatioiden määrään liittyviä arvioita.
13. Taulukonkäsittelyfunktiot	Palauttavat taulukoita ja käsittelevät sekä muokkaavat niitä laskennassa käytettäväksi.
14. Tekstifunktiot	Funktioiden avulla voidaan palauttaa esimerkiksi vain osa tekstijonon kirjaimista, etsiä tekstiä merkkijonosta tai yhdistää merkkijonon arvot. Sisältää myös lisätoimintoja päivämäärien, lukujen ja aikojen muotojen hallitsemiseen.
15. Aikatieotfunktiot	Laskutoimitukset käyttävät hyväkseen sisäisiä tietoja kalenterista ja päivämääristä. Voidaan käyttää merkityksellisten vertailujen luontiin esimerkiksi myynnin ja varastojen vertailukelpoisille ajanjaksoille Avustaa koosteiden ja laskelmien kanssa.

Funktioilla voidaan käsitellä dataa eri tavoilla ja niitä voidaan hyödyntää sisäkkäin DAX:n syntaksissa, kun luodaan laskureita tai laskennallisia sarakkeita. Laskennallinen sarake, jolla yhdistetään kaksi riviä toisiinsa voi näyttää esimerkiksi tältä:

Myynnin bruttohinta (sarake) =

'MyyntiFakta'[VerotonHinta] + 'MyyntiFakta'[VeroSumma]

Tämänkaltaisella ratkaisulla saadaan aikaan myynnin kokonaishinta, jossa veroton hinta ja veron määrä saadaan yhdistettyä yhteen sarakkeeseen. Excel-taustaiselle käyttäjälle sarakkeiden yhdistäminen voi tuntua järkevältä mutta tietomallipohjaisessa BI-analytiikassa samaa dataa ei ole järkevää tallentaa tietomallissa useaan eri paikkaan saatavaksi. Tämä vaikuttaa mallin kokoon sekä nopeuteen, varsinkin kun datamäärät kasvavat suuriksi. Siksi vastaava myynnin kokonaishinta voidaan toteuttaa seuraavan kaltaisena laskurina:

Myynnin bruttohint (laskuri) =

sum(MyyntiFakta[VerotonHinta]) +

sum(MyyntiFakta[VeroSumma])

Käyttäessä DAX-koodia on hyvä noudattaa sisennyksiä ja asettelua. Nämä asiat helpottavat laskureiden lukua ja sisäistämistä. DAX:n syntaksiin luomiseen voidaan käyttää apuvälineitä kuten esimerkiksi DAX Studiota. DAX Studion avulla DAX:n avulla luodut kaavat voidaan muotoilla helpommin ymmärrettävään muotoon. Laskureissa ja syntaksissa on syytä noudattaa helppolukuisuuden ja ymmärryksen parantamisen takia ihmiselle tarkoitettuja lukemiseen liittyviä nimiä. Esimerkiksi pankkien nimiä käsitellessä lienee täysin selvää, että uudelle osaamattomammalle tietomallinnusmaailman ulkopuolelta tulevalle raporteja käyttävälle ihmiselle S-Pankki on helpompi lukea kuin SBANFIHH, tai POP Pankki on helpompi lukea kuin POPFFI22. Usein nämä nimeämiset ovat hoidettu sarakkeisiin jo tietovarastossa mutta esimerkiksi laskureita nimettäessä on syytä välttää lyhenteiden käyttöä ja nimetä laskurit mahdollisimman helppolukuisiksi ja hyvin avatuiksi niin, että kaiken tasoiset käyttäjät ymmärtävät sisällön mahdollisimman pienellä vaivalla.

2.5. SQL Server Analysis Services (SSAS) Tabular-malli


Tabular-mallit ovat olleet alun perin Microsoft SQL Server Analysis Services (SSAS) palvelimella toimivia muistipohjaisia relaatiotietokantoja. Power BI:n tietomallien toiminta

perustuu tähän teknologiaan ja sen alla olevaan VertiPaaS-moottoriin. Tuote on pohjimmiltaan sama, mutta yhteensopivuustaso ja siihen sitoutuvat ominaisuudet eroavat hieman keskenään. Tabular-malleja voidaan julkaista suoraan Power BI Premiumiin tai Azure Analysis Services -palveluihin. Viime aikoina Tabular-mallit ovat nousseet takaisin organisaatioille vaihtoehtoiksi johtuen niiden kyvystä hallinnoida ja päivittää dataa sekä käsitellä suurempia datamääriä kuin mitä Power BI Desktopilla tehdyt tietomallit voivat käsitellä.

Tabular-malli on muistipohjainen relaatiotietokanta. Tabular-malli voi olla myös tai vaihtoehtoisesti DirectQuery (suorakysely) -pohjainen relaatiotietokanta. Muistipohjainen tietomalli ei vaadi kiintolevytilaa toimiakseen ja sen vahvuuksiin kuuluu esimerkiksi nopeampi pääsy dataan (Wilson, 2017, s.8). Muistipohjaisessa mallissa data on tallennettuna tietokoneen välimuistiin. Tabular-malli käyttää DAX-kieltä mukana sarakkeissa ja laskureissaan.

Tabular-mallia tehdessä ja Power BI -tietomalleja rakennettaessa tärkeää ymmärtää Tabular-mallin peruskonseptit. Tabular-mallin neljä pääperiaatetta ovat taulut, sarakkeet, laskurit ja relaatiot (Wilson, 2017, s.19). Näiden lisäksi mallintamisessa voidaan käyttää hyödyksi useista sarakkeista koostuvia hierarkioita.

Taulut ovat tietolähteistä tietomallin muistiin tuotuja datakokonaisuuksia, jotka koostuvat sarakkeista ja riveistä. Taulujen mukaan tuonti ei vaadi datan muokkaamista erilaisiin skeematyyppisiin rakenteisiin. Muokkaukset tietomalliin pystytään tekemään mallinrakennusvälineellä, kuten esimerkiksi Visual Studiolla, Power BI:llä tai Tabular Editorilla. Tämä sallii nopeammat kehitys- ja muutossykliä tietomalleja rakentaessa, kun tietomalleja ja raportteja kehittävät BI-tiimit eivät ole riippuvaisia lähdejärjestelmän muutoksista. Tällöin esimerkiksi datan mallinukseen ja muotoiluun liittyvät seikat voidaan tehdä mallinrakennusvälineessä. Taulun sisältö voi olla esimerkiksi kuvan 9 kaltainen:




	Location	Street	City	State	Zipcode
1	Lincoln Memorial	2 Lincoln Memorial ...	Washington	DC	20037
2	Washington Mo...	2 15th St NW	Washington	DC	20024
3	Jefferson Memorial	701 E Basin Dr SW	Washington	DC	20242
4	Empire State Bui...	350 5th Ave	New York	NY	10118
5	Grand Central T...	89 E 42nd Street	New York	NY	10017
6	Hoover Dam	Hoover Dam	Boulder City	NV	89006
7	St. Louis Arch	100 Washington Ave	St. Louis	MO	63102
8	Independence Hal	520 Chestnut St	Philadelphia	PA	19106
9	The Alamo	300 Alamo Plaza	San Antonio	TX	78205

Kuva 9. Tietokantataulun sisällön esimerkki (Wilson, 2017, s.20)

Sarakkeet ovat edellisessä kuvassa näkyvillä riveillä esimerkiksi nimellä ”Location”. Sarakkeiden datatyyppejä on seitsemän erilaista. Datatyytit ovat listattuna aiemmassa DAX-kappaleessa laskurien toiminnan yhteydessä. Taulu koostuu useammasta rivistä, jotka sisältävät useamman sarakkeen mutta kuitenkin aina vähintään yhden sarakkeen. Yksi rivi sisältää yhden entiteetin datan, esimerkiksi myyntitapauksen tai asiakkaan tiedot. Tabular-mallia rakentaessa taulut yhdistetään toisiinsa relaatioiden avulla.

Relaatioissa kentät yhdistetään toisiinsa avainkenttien avulla. Avainkenttien avaimet voivat toistua faktatauluissa useamman kerran mutta tarkemman tiedon sisältävässä dimensiotauluissa avainkenttiä tulisi olla aina yksi riviä kohden. Tässä esimerkissä dimensiotaulussa sijaitsevaa avainkenttää kutsutaan perus- eli pääavaimeksi ja faktataulussa sijaitsevaa avainkenttää viiteavaimeksi (Jaakola & Sarja, 2006). Yhdistämällä pää- ja viiteavaimen toisiinsaadaan aikaan tietokantataulujen välinen yhden suhde moneen relaatio (kuva 10), jonka avulla datan rikastaminen tapahtuu.



Kuva 10. Esimerkki luodusta relaatiosta (Wilson, 2017, s.22)

Relaatioiden avulla saadaan datan mallintamisen ja järkeistämisen lisäksi säästettyä kustannuksia tietokantavarastoinnissa sekä nopeutettua raportoinnin kehittämissä. Tällöin esimerkiksi asiakastietoihin voidaan lisätä uusia kuvaavia dimensiotietoja ja dataa voidaan analysoida ilman, että jokaiselle faktariville tarvitsee lisätä tätä tietoa. Tämä mahdollistaa nopeamman analysoinnin, kun ladattavat ja päivitettävät rivimäärät ovat pienempiä.

Relaatioita voivat olla yhden suhde yhteen (one-to-one) -ja yhden suhde moneen (one-to-many) -relaatioita. Monen suhde moneen (many-to-many) relaatiot ovat mahdollisia tietyin rajauksin mutta niiden käyttöä ei suositella. Relaation suhde kertoo kuinka data linkittyy toisiinsa. Yhden suhde yhteen -relaatioissa molemmissa tauluissa on yksi avain yhtä riviä kohden. Rivit luovat relaation toisiinsa, eivätkä avaimet toistu kummassakaan taulussa useammalla rivillä. Yhden suhde moneen -relaatio on taas useimmin käytetty relaatio, jolla linkitetään usein faktataulu dimensiotietoon. Taulujen välillä voi olla vain yksi aktiivinen relaatio (Mabee, 2020). Laskureissa voidaan hyödyntää inaktiivisia relaatioita taulujen välillä. Käyttämällä yhtä dimensiossa sijaitsevaa päiväsaraketta voidaan tilausten määrä kertoa tilauspäivämäärän ja toimituspäivämäärän mukaan tekemällä asianmukaiset laskurit.

Tabular-mallit ovat pohjimmiltaan BI-maailmassa vanhaa teknologiaa. Teknologian voidaan kuitenkin katsoa viime aikoina nostaneen suosiotaan johtuen sen läheisyydestä ja integrointimahdollisuuksista esimerkiksi Power BI -välineen avulla. Power BI:n ja Tabular-mallien laskenta- sekä toimintatavat ovat samanlaisia, ja Tabular-mallit mahdollistavat suurempien datamäärien käsittelyn. Yleisesti voidaan katsoa pilvipalveluiden kuten Azure Analytics Servicen sekä siellä sijaitsevien skaalausmahdollisuuksien helpottavan tietomallien hallintaa. Power BI:n myötä Azure Analysis Services -palveluiden ja sitä kautta Tabular-mallien kehittäminen on saanut Microsoftin puolelta uutta vauhtia, ja välineiden suosiot antavat vahvaa indikointia siitä, että käyttöä tulee löytymään jatkossakin.


2.6. VertiPaq-moottori

VertiPaq on yleisesti käytetty sana DAX-pohjaisten tietomalliratkaisujen taustalla toimivista moottoreiden kokonaisuuksista. VertiPaq-termin virallinen nimi on xVelocity in-memory analytical engine (Russo & Ferrari, 2015, s.399). Tässä diplomityössä moottorista käytetään selkeämpää ja alan yleisiä käytäntöjä myötäilevää termiä VertiPaq, joka on saanut nimensä moottorin kehitysvaiheen projektinimestä. VertiPaq:n toiminta perustuu muistipohjaiseen sarakepohjaiseen tietokantaan. Sarakepohjainen tietokanta toimii RAM (Random Access

Memory) -muistissa. RAM-muistissa sijaitsevan tietokannan data on jatkuvasti käytössä, eikä se vaadi levyille kirjoittamista. Muistissa toimivien VertiPaq-moottorilla käytettävien tietokantojen prosessointi koostuu Russon ja Ferrarin (2015, s.400) mukaan seuraavista vaiheista:

1. Lähdetietojen lukeminen, muuntaminen VertiPaq:n mukaiseksi saraketietorakenteeksi sekä sarakkeiden enkoodaus ja pakkaus
2. Sarakekirjastojen ja indeksien luonti jokaiselle sarakkeelle
3. Tietokantarakenteiden rakentaminen sarakkeiden sisäisille suhteille
4. Laskennallisten sarakkeiden (Calculated columns) kaavojen komputointi ja pakkaus.


Sarakepohjaisen tietokannan ideana on järjestää data niin, että jokaista riviä ei tarvitse käydä läpi erikseen. Sarakepohjaisessa kannassa numeraalisia datatyppejä sisältävät sarakkeet enkodataan vähemmän tilaa vievään muotoon. Tätä prosessia kutsutaan arvojen enkoodaamiseksi. Esimerkiksi tuotteen hinnan kertova numero 216 vie 8 bittiä tilaa, kun taas numero 22 vie 5 bittiä tilaa. Tämänkaltaisen pakkaus saadaan vähentämällä kaikista arvoista pienin mahdollinen arvo, jolloin numerot lähtevät nolasta ylöspäin ja jokaisen sarakkeen oma rivi vie vähemmän tilaa. Lyhyillä sarakerivimäärillä tällä ei ole suurta merkitystä mutta jos kolmen bitin tilansäästö kerrotaan muutamalla miljoonalla rivillä niin voidaan todeta tämän pakkauksen olevan toimiva keino säästää tilaa (Russo & Ferrari, 2015, s.404–405). Kuva 11 havainnollistaa pakkauksen käyttämää toimintatapaa.



Kuva 11. Russon ja Ferrarin (2015, s.404) esimerkkiä mukaileva numeraalisten arvojen enkoodauksen toimintatapa


Arvojen pakkauksen lisäksi VertiPaq-moottori voi tehdä vaihtoehtoisesti sarakkeelle sanakirjastojen enkoodauksen. Russo ja Ferrari (2015, s.406) kertovat kirjassaan, että sarakepohjaisten arvojen muuttaminen taustalla numeraaliseen ID-arvoon tarkoittaa, että datatyypillä ei ole SSAS-mallinnuksessa suurta merkitystä. Avainkenttinä on kuitenkin tietomallin luettavuuden ja selkeyden takia viisasta käyttää numeraalisia arvoja.

Sarakkeiden sanakirjastoon enkoodaamisessa VertiPaq-moottori luo arvoille ID:t ja nimen. ID-kenttien avulla saadaan vähennettyä tietomallin käyttämää tilaa. Mikäli arvo on jokin muu kuin integer, toteuttaa VertiPaq aina sarakkeiden sanakirjastotyyllisen enkoodauksen. VertiPaq-moottori voi kuitenkin tietyissä tapauksissa tehdä sarakkeiden sanakirjastotyyppisen pakkauksen integer-datatyypin omaaville sarakkeille, mikäli esimerkiksi arvot ovat laajalta skaalalta ja eroavat toisistaan paljon (Russo & Ferrari, 2015, s.409). Sarakkeiden ID-arvojen ja nimien luonnin jälkeen tietomallin prosessoinnin aikana moottori korvaa taustalla olevat alkuperäiset sarakkeiden arvot numeroilla datan yhdistämistä varten sekä luo tarvittavat relaatiot sanakirjastoihin. VertiPaq näyttää loppukäyttäjälle aina vain varsinaiset arvot. Esimerkin yksittäiseen sarakkeeseen tehdystä kirjastomuotoisesta tallennuksesta näkee kuvasta 12.




Kuva 12. Russon ja Ferrarin (2015, s.405) esimerkkiä mukaileva sanakirjastojen enkoodauksen toimintatapa

Arvojen ja sanakirjastojen enkoodaus toimii mallin tilaa vähentävänä keinoina. VertiPac-moottori tarjoaa näiden kahden pakkaustekniikan lisäksi kolmannen tekniikan datamäärän pakkausta varten. RLE:n (Run Length Encoding) tarkoitus on pienentää tietomallin koon määrää välttämällä sarakkeiden arvojen turhaa toistoa (Russo & Ferrari, 2015, s.406). RLE-enkoodauksen pakkaus toimii heuristisen algoritmin avulla automaattisesti (Russo, & Ferrari, 2015 s.410). Heuristisella algoritmilla tarkoitetaan tarpeeksi lähelle parasta mahdollista ratkaisua pyrkivää algoritmia. Algoritmi järjestää sarakkeet optimaaliseen rivijärjestykseen riippuen kokonaisen taulun sisällöstä ja antaa sarakkeissa sijaitseville arvoille aloitusrivit ja päätösrivit. Esimerkin kvartaalitiedon sisältävälle sarakkeelle ja sen RLE-enkoodaukselle näkee kuvasta 13.



Kuva 13. Russon ja Ferrarin (2015, s.407) esimerkkiä mukaileva RLE-pakkauksen toimintatapa

RLE-pakkaus voi kuitenkin jäädä tekemättä, mikäli kyseessä on esimerkiksi vain yksittäisiä tai lähestulkoon samanlaisia arvoja omaava timestamp-tieto. Timestamp-tiedossa erotukset ovat millisekuntien tasolla, jolloin pakkaus veisi alkuperäistä arvoa enemmän tilaa. Arvot voivat myös jäädä pakkaamatta, jos kyseessä on jokaisella rivillä yksittäisen arvon omaava avainkettä. Tämänkaltaisissa tapauksissa pakkaus veisi enemmän tilaa kuin alkuperäinen arvo, joten VertiPaq jättää arvojen enkoodauksen, sanakirjastojen enkoodauksen ja RLE-pakkauksen väliin. RLE-pakkauksen toteutuessa tämä kuitenkin yhdistetään aina joko arvojen tai sanakirjojen enkoodauksen kanssa. Sanakirjastojen enkoodauksen kanssa yhdistyvässä RLE-pakkauksessa VertiPaq-moottori vie alkuperäisen sarakkeen arvon taulukkomuotoon. Tällöin aiempaa sanakirjastoesimerkkiä mukaillen on kvartaalin sisältämät arvot muutettu taustalla ID-arvoiksi ja kirjastoksi. Samalla rivit ovat aseteltu lähes optimaaliseen järjestykseen heuristisen algoritmin avulla. Kuvasta 14 näkee esimerkin sanakirjastojen enkoodauksesta ja RLE-pakkauksen yhdistelmäprosessista. Arvojen enkoodauksen yhdistelmässä käytetään suoria numeroita sanakirjaston sijaan.



Kuva 14. Russon ja Ferrarin (2015, s.408) esimerkkiä mukaileva sanakirjastojen enkoodauksen ja RLE-pakkauksen yhdistetty toimintatapa

VertiPaa-moottori tekee edellä mainitut toimenpiteet heuristisen algoritmin avulla automaattisesti niin, että käyttäjän tarvitsee keskittyä pelkästään tietomallin rakentamiseen niin, että data esiintyy optimaalisella tavalla. Perusajatuksena sarakepohjaisille VertiPaa moottoria käyttäville malleille on käyttämättömien kolumnien poisto sekä liian tarkalla tasolla olevan tiedon poisto.. VertiPaa-moottoria käyttävien mallien toimintakyky ja nopeus ei ole riippuvainen rivien määrästä, vaan sarakkeiden yksittäisten arvojen määrästä.

Diplomityön tekijä on nähnyt urallaan VertiPaa moottorilla toimivia malleja, joissa optimoidussa noin 400 miljoonan rivin faktataulun omaavassa mallissa koko on ollut noin 2 GB. Samalla optimoimaton, mutta kuitenkin kokonaisuudeltaan täysin erillinen tietomalli, on pitänyt sisällään 40 miljoonaa riviä ja koko on ollut 20 GB. Tästä voidaan todeta, että sarakepohjaisisten tietomallien rakentamisessa ja kehittämisessä on olennaista ajatella rivimäärän sijasta datassa olevia yksittäisiä sarakekohtaisia arvoja eli kardinaliteetin vähentämistä. Kardinaliteetin vähentäminen tarkoittaa joukossa olevien yksittäisten arvojen vähentämistä. Käytännössä tämä voi tarkoittaa esimerkiksi timestamp-muodossa olevasta ”11.01.2022 15:43” -kentästä kellonajan poistamista, mikäli kellonaikoja ei tietomallissa tarvita. Tällöin kaikki 11.01.2022 -päivämäärällä olevat sarakkeiden arvot saadaan pakattua pienempään ja helpommin käytettävään tilaan, kun jokainen rivi ei tallennu omaksi riviksi sanakirjastoon.


Liian tarkalla tasolla oleva tieto voi tarkoittaa myös yksittäisiä kellonaikoja sisältäviä date-time-sarakkeiden muuntamista kahdeksi päivämäärän ja kellonajan kertoviksi erillisiksi sarakkeiksi. Malleja rakentaessa tulee ottaa huomioon muitakin asioita kuten esimerkiksi liiketoiminnan tarpeet, datan ajantasaisuuden tarve sekä tietomallien päivitykseen menevät ajat.

3. Datan mallinnus ja parhaat käytännöt

Luvussa kolme käydään läpi yleisesti Power BI -ja SSAS Tabular-mallinnukseen liittyviä käytäntöjä ja toimintamalleja. Luvun 3 kappaleissa on tarkoitus tuoda ilmi datan mallintamiseen liittyviä parhaita käytäntöjä. Parhaiden käytäntöjen noudattaminen parantaa ratkaisujen laatuja sekä helpottaa vuosien yli jatkuvaa kehitystä. Parhaiden käytäntöjen huomioon ottaminen jo suunnitteluvaiheessa luo mahdollisuudet ratkaisujen kestävyydelle, pitkäjänteiselle kehitykselle sekä auttaa välttämään teknologisten umpikujien kohtaamisen.

3.1. Tähtimalli

Tähtimalli (Star Schema) on vähintään kahdesta taulusta koostuva tietomalli, joka on samalla yksi suosituimmista Power BI:ssä ja SSAS:ssä käytetyistä tietomallityypeistä. Tähtimalli koostu yhdestä faktataulusta ja useasta dimensiotaulusta. Tähtimalli-pohjaisten tietomallikokonaisuuksien toiminta perustuu normalisoituun relaatiotietokantaan jonka faktataulussa sijaitsevat transaktiotason tapahtumat, esimerkiksi myyntitapahtumista. Tähtimallin dimensiotauluissa sijaitsevat dataa kuvailevat tiedot, esimerkiksi asiakastiedot. Tähtimallin tietomalli on kuvan 15 kaltainen.



Kuva 15. Esimerkkirakenne tähtimallista. * kuvaa vierasavainta ja 1 pääavainta


Tähtimallin vahvuudet pohjautuvat taulujen normalisointiin. Normalisoinnilla tarkoitetaan sitä, että data sijaitsee vain yhdessä paikassa. Siksi tähtimallia toteuttaessa on erittäin tärkeää, että turhat kentät poistetaan tai jätetään kokonaan ottamatta mukaan. Kuvaavan dimensiotiedon on aina hyvä sijaita tähtimallia hyödyntävässä SSAS- tai Power BI -mallissa omassa dimensiotaulussaan, tai muuten datan toistuminen useassa eri paikassa tulee syömään hyvän mallinnuksen hyötyjä pois. Saman tiedon sijaitessa useammassa eri paikassa tietomalli ei ole yksiselitteinen. Moniselitteinen tietomallinnus vaikeuttaa mallin ymmärtämistä, kehittämistä ja luo teknistä velkaa. Yksiselitteinen tietomalli mahdollistaa helpompi-lukuisten laskurien tekemisen ja tietomallin sekä raporttien nopeamman, helpomman ja paremman kehittämisen.

Ferrari ja Russo (2017) kertovat kirjassaan ”Analyzing Data with Microsoft Power BI and Power Pivot for Excel”, että tähtimallin yksi suurimmista hyödyistä on sen helppo ymmärrettävyys ja hallinta. Samalla Ferrari ja Russo (2017) mainitsevat muiden mallinnustyylien kuten lumihitulemallin olevan tarpeellinen välttämättömyyksien vuoksi. Tietokannan ja

tietolähteiden normalisoinnin avulla sekä tähtimallia hyödyntämällä tietomallin koko pienenee huomattavasti. Tämän eron huomaa helposti vertailemalla tähtimallia denormalisoituun saman datan omaavaan, mutta silti tietomalliksi lueteltavaan tauluun. Verkkoartikkelissaan Russo ja Ferrari (2021) kertovat pienemmän tietomallin muodostavan tähtimallin käyttämäksi muistikooksi 16.80 GB ja lihavamman denormalisoidun yhtä taulua käyttävän mallin kooksi 44.51 GB. Tämä tarkoittaa sitä, että analyysipalvelimella suoritettavan käytettävän muistin määrä on yhdessä taulussa sijaitsevassa Tabular-mallissa 2.65 kertaa suurempi. Hyvin suunnitellun tietomallin hyödyt ovat siis huomattavan arvoiset. Esimerkiksi Azure Analysis Services palvelua ostaessa alle 25 GB:n hinta on Microsoftin Azuren Analysis Services -hinnoittelun mukaan (Liite 1, 2021) 1 323 € kuussa, kun taas laajempaan huonommin suunnitellun malliin minimissään vaadittava 50 GB:n muistikanta on hinnaltaan 2 647 € kuussa. Tämä tarkoittaa käytännössä hinnan tarpeetonta tuplaantumista. Hyvällä tietomallisuunnittelulla ja normalisoiduilla tähtimalleilla voidaan vuosittain tehdä todistettavasti minimissään 15 888 € säästöt. Saadut hyödyt ovat kuitenkin todennäköisesti korkeampia, sillä tietomallit käyttävät muistia datan tallentamisen lisäksi myös laskennan suorittamiseen.

3.2. Lumihiutalemalli

Lumihiutalemalli (Snowflake Schema) on tähtimallia muistuttava tietomalli. Toimintaperiaatteet ovat datan normalisointiin liittyen samanlaiset mutta lumihiutalemallin rakenne on hieman erilainen. Lumihiutalemallissa dimensioiden kuvaava tieto sijaitsee usein useammassa eri taulussa, jotka yhdistyvät syvemmälle dataan, kuten kuvasta 16. ilmenee.



Kuva 16. Esimerkki lumihuutalemallin tauluista ja niiden yhteyksistä


Lumihuutalemallissa esimerkiksi suuressa organisaatiossa yksi yritys voi sisältää useamman liiketoimintaryhmän ja yksi liiketoimintaryhmä taas voi sisältää useamman kustannuspaikan, ja yhdellä kustannuspaikalla voi olla useampi myymälä. Tämänkaltaisen rakenteen kuitenkin vaikeuttaa datan lukemista.

Ferrari ja Russo (2017, s.223) pitävät kirjassaan lumihuutalemallia Business Intelligencen maailmassa yhtenä yleisimmästä käytettynä tietomallityyppinä. Ferrari ja Russo (2017, s.223) mainitsevat kirjassaan totuudeksi myös sen, ettei lumihuutalemallit ole huonoja ratkaisuja, vaikka tähtimalliin verratessa suorituskyky heikkenee lievästi. Lumihuutalemallin käyttötarve on usein välttämätön. Samalla lumihuutalemallia ei kuitenkaan suositella

käytettäväksi, jos se ei ole välttämätöntä, sillä yksinkertaisempi tietomalli tekee DAX:lla koodaamisesta ja kehittämisestä helpompaa. Ohjaavan tiedon sisällyttäminen yhteen dimensiotauluun on Power BI - ja SSAS-mallinnuksessa parempi toimintatapa kuin tiedon sisällyttäminen useampaan tauluun. Kehittäminen on nopeampaa ja yksittäisessä taulussa sijaitsevat dimensiotiedot helpottavat DAX-koodaamista ja tekevät siitä helpommin luettavaa.

3.3. Header- ja detail-taulut

Header- ja detail-tiluilla tarkoitetaan otsikko- ja rivitason dataa. Yksi esimerkki tämänkaltaisessa lähdejärjestelmän tietorakenteessa voi olla esimerkiksi ostotilaukset ja niiden rivitason data. Ostotilaus voi sisältää esimerkiksi tilaajan tietoja kuten tilauksen numeron ja tilauksen kokonaisalennusprosentin. Ostorivit-taulu taas sisältää usein tarkemman tuotetason tiedon tilausmäärineen ja yksikköhintoineen. Tämänkaltaisen kahden taulun välillä toimiva yhteys (kuva 17) ei kuitenkaan toimi muistipohjaisissa relaatiotietokannoissa.



Kuva 17. Ferrari ja Russo (2017 s.30) Kirjan mallia mukaileva header- ja detail-tilun yhteys. PK = PrimaryKey, pääavain ja FK = ForeignKey, vierasavain


Ostotilausta ja ostoriviä voidaan ajatella niin, että ostotilaus on dimensiotaulu ja ostorivi on faktataulu. Ostotilauksen ollessa ohjaavaa tietoa sisältävä dimensiotaulu, tehdään tietomallista tarpeettomasti lumihitalemallin mukainen. Lumihitalemallin tyylinen toteutus vaikuttaa kuitenkin aiemman 3.2. kappaleen kertomuksen mukaisesti negatiivisesti käyttömahdollisuuksiin. Tämän tyyppisissä tilanteissa data kannattaa yhdistää yhdeksi tauluksi tai näkymäksi jo ETL-vaiheessa. ETL-vaiheessa tiedot tulisi siirtää dimensiomaisesta ostotilaus-

taulusta ostorivi-taulun sisälle yhdistämällä data tilausnumeron avulla toisiinsa, ja viemällä tilauskohtaiset tiedot kuten kauppa, asiakas, valuutta, tilauspäivämäärä, alennusprosentti ja kokonaisalennus ostorivitauluun. Tämänkaltaisen tilannekohtainen denormalisointi mahdollistaa datan helpomman luettavuuden ja ymmärtämisen. Tällöin käytettävissä oleva tietomalli sisältää tarpeellisen tiedon samalla helpottaen laskureissa ja laskennallisissa sarakkeissa käytettävän DAX-koodin käyttämistä.

VertiPac-pohjaisten tietomallien sanakirjastoenkoodauksen ja RLE-pakkauksen toimiessa aiemmin mainitun tavan mukaisesti on todistettua, että tämänkaltaisissa tapauksissa kaksi header- ja detail-tilua on järkevää yhdistää yhdeksi tauluksi. Tämän kaltaisessa esimerkissä vältetään lumihiutalemallin käyttö joka helpottaa kehitystyötä. Koko tietomallia ei kannata kuitenkaan liittää yhdeksi tauluksi. Datan litistäminen eli taulujen yhdisteleminen toimii hyvin silloin kun taulut liittyvät suoraan toisiinsa, kuten tässä tapauksessa tilausnumeron kautta, mutta muissa tapauksissa se ei välttämättä ole kaikista toimivin vaihtoehto. Yleisesti taulujen yhdistäminen mahdollistaa tähtimallin toimimisen ja lumihiutalemallin välttämisen, niin silloin taulut ovat järkevä yhdistää.


3.4. Useamman faktataulun käyttö

Tähtimalliin pyrkiminen on tietomallia rakentaessa aiemmin mainittujen tapojen mukaisesti järkevin vaihtoehto mallinnusta varten, mikäli liiketoimintakysymyksiin on mahdollista vastata tällä tavalla. Tämänkaltaisen tapaus voi olla esimerkiksi raportti, jossa halutaan analysoida osto- ja myyntidataa. Osto- ja myyntidata sijaitsevat eri tauluissa ja kahta faktataulua käyttäessä yksi tapa yhdistää tämänkaltaiset tiedot toisiinsa on luoda yhteydet molempiin faktatauluihin dimensioiden avulla kuvan 18 tyyliä.




Kuva 18. Esimerkki ostotaulun ja myyntitaulun yhdistävästä tuotedimensiosta

Yhdistämällä myynti- ja ostotaulu tuotekategoriaan luodaan mahdolliseksi molempien taulujen suodattaminen tuotedimension tietojen avulla. Tämä voi tarkoittaa esimerkiksi sitä, että voit valita tuotteen nimen tai valmistusmaan perusteella, ja tarkastella sen osto- ja myyntitietoja samoissa visualisoinneissa. Nämä kuitenkin vaativat toimiakseen erilliset laskurit, koska varsinaiset tilaustiedot ostojen ja myyntien suhteen ovat eri tauluissa. Jos taulut ovat vahvasti denormalisoituja eikä avainkenttiä ja dimensiotauluja löydy, niin tällöin kannattaa normalisoida taulut tai luoda vaihtoehtoiset näkymät ja luoda dimensiotieto suoraan tietovarastoon. Samankaltaiset dimensiotietojen yhdistämiset voidaan tehdä kaikkiin avainkenttiin. (Ferrari & Russo, 2017. s. 40–43) Esimerkki avainkenttien datan yhdistävistä kahdesta fakta- ja dimensiotaulun koostavasta tietomallista löytyy kuvasta 19.



Kuva 19. Esimerkki kahden faktataulun tietomallista, jossa dimensiot ovat yhdistettyjä toisiinsa

Edellä olevan kuvan tavalla esitetty tietomalliratkaisu mahdollistaa myynti- ja ostotietojen suodattamisen kalenterin ja tuotetietojen avulla. Tietomallissa on käytetty vain suositeltuja yhden suunnan relaatioita. Jos halutaan luoda esimerkiksi laskurin, joka kertoo ostot vain niille tuotteille, joita on myyty, tulee sinun ratkaista tämä joko DAX-kielen avulla tai vaihtoehtoisesti suodattamalla dataa tai visualisointeja kuvan 20 tyyliä käyttäen hyödyksi toisiin faktatauluihin perustuvia laskureita. Näiden avulla kyetään suodattamaan näytettävää dataa valittujen kuvaavien tietojen, kuten tässä tapauksessa tuotteen nimen perusteella.



Visual filterissä ei rajoituksia

Nimi	Ostot	Myynnit
Pahvilaatikko	50,00 €	60,00 €
Peruna	45,00 €	
Total	95,00 €	60,00 €

Myynnit <> blank Visual filterissä

Nimi	Ostot	Myynnit
Pahvilaatikko	50,00 €	60,00 €
Total	50,00 €	60,00 €

Filters

Search

Filters on this visual

Myynnit
is not blank

Show items when the value

is not blank

☒ And ☐ Or

Apply filter

Kuva 20. Useampaa faktataulua käyttäessä voidaan suodattaa visualisointeja

Hyvänä muistisääntönä useamman faktataulun käyttöön voidaan pitää dimensioiden ja suodattimien käyttöä, mikäli tämä on mahdollista. Denormalisointi eli avainkenttien kuvaavan tiedon vienti tauluihin toimii mahdollisena vaihtoehtona, mikäli esimerkiksi faktataulut sisältävät tietoja jotka eivät suoranaisesti liity toisiinsa. Datan vieminen yhteen faktatauluun kannattaa Power BI -mallinnukseen liittyvistä toiminnallista näkökulmista johtuen toteuttaa aina sen ollessa mahdollista. Liika denormalisointi tekee kuitenkin faktataulujen keskinäisestä suodattamisesta mahdotonta. Tämän korjaamiseksi tulee valita hyvä joukko dimensioita, joiden välillä päästään suodattamaan faktataulujen arvoja. Samalla useamman faktataulun omaavan mallin rakentaminen on kompleksista relaatioiden hallintaa. Useamman faktataulun käyttö luo helposti moniselitteisiä tietomalleja, joissa laskurit voivat antaa useita eri lukuja riippuen, missä tietoja näytetään ja mitä tietoja suodatetaan. DAX-moottorin on vaikea käsitellä moniselitteisiä ratkaisumalleja, ja ongelman voi ratkaista tällöin taulujen monistamisella ja denormalisoinnilla. (Ferrari & Russo, 2017. s.53.)

3.5. Nimeämiskäytännöt

Tietomalliin haettaessa dataa se ladataan tietolähteestä, joka on usein tietovaraston yksittäisessä tietokannassa oleva taulu. Tietovaraston ja mallien nimeämiskäytännöt voivat olla

toisistaan eroavia ja saattavat omata kehitysvelkaa pitkältäkin ajalta. Tietokannasta dataa ladattaessa voivat taulut sisältää useita erityylishä nimeämiskäytäntöjä kuten taulukosta 2 ilmenee.

Taulukko 2. Esimerkkejä tietokannan taulujen nimeämiskäytännöistä

Dimension nimi	Faktan nimi	Näkymän nimi
d_Dimensio	f_Fakta	v_Nakyma
dDimensio	fFakta	vNakyma
dim_Dimensio	fact_Fakta	View_Nakyma
dimDimensio	FactFakta	ViewNakyma

Tietolähteistä tulevat taulut ja niiden sarakkeet saattavat sisältää tietokannoissa erilaisia nimiä. Hyvien nimeämiskäytäntöjen toteuttaminen ja vahtiminen jää silloin toteutettavaksi tehtäväksi tietomallin ja raportin kehittäjälle. Ferrari ja Russo (2017) mainitsevat kirjassaan seuraavat seitsemän sääntöä Power BI -tietomallien taulujen ja sarakkeiden nimeämisiin liittyen:

Taulukko 3. Tietomallin taulujen suositellut nimeämissäännöt (Ferrari & Russo, 2017, s. 20–21)

Sääntö	Selite
Taulujen nimien tulisi sisältää vain liiketoiminnan sisällön mukaista dataa	Jos taulun nimi on Asiakas, niin taulun tulisi sisältää vain asiakkaita. Jos taulun nimi on Tuote, niin taulun tulisi sisältää vain tuotteita.
Käytä isoja kirjaimia erottamaan taulujen erilliset sanat	Jos taulu sisältää tuotteiden kategoriat, niin taulun nimen tulisi olla esimerkiksi TuoteKategoria.
Taulujen faktojen nimien tulisi sisältää liiketoiminnan nimen faktalle, joka on aina monikko	Myyntitaulun nimen tulisi tällöin olla aina Myynti ja ostotaulun nimi Ostot. Monikon käyttämisellä tietomallin katsomisessa ymmärtää tällöin helpommin, että yksittäisellä asiakkaalla on useampi myyntitapahtuma. Tämä vahvistaa relaatioiden ymmärtämistä.
Vältä nimiä, jotka ovat liian pitkiä	Koita etsiä mahdollisimman hyvä ja helposti luettava lyhyt nimi. Älä käytä turhia sanoja. Liian pitkät nimet kuten TavaroidenLähetysMaa-KunJälleenmyyjäMyyTavaran ovat epäselviä.
Vältä nimiä, jotka ovat liian lyhyitä tai lyhenteitä	Lyhenteiden käyttö lisää raporttien epäselvyyttä. Raporttien käyttö tulee suunnitella koko organisaatiotasolle ja täten välttää lyhenteiden käyttöä. Kaikkien ymmärrys ei ole samalla tasolla ja lyhenteiden selvittäminen vie aikaa.
Avainkentän nimessä tulee aina olla aina maininta avaimesta	Jos sarake on avainkenttä, esimerkiksi Asiakastaulu, niin silloin asiakastaulun avainkentän nimi, joka yhdistyy faktatauluun, tulisi olla esim. asiakasAvain tai CustomerKey
Mieti ymmärtävätkö kaikki valitsemasi nimen	Nimeä miettiessä kannattaa kysyä itseltään, että ymmärtävätkö kaikki nykyiset ja tulevat käyttäjät valitut nimet. Jos ajattelet vain nykyisten käyttäjien ymmärrystä, on todennäköistä, että tulevaisuudessa kaikki eivät nimeä ymmärrä, ja että tästä aiheutuu helposti vältettävissä olevia ongelmia.

Hyviä nimeämiskäytäntöjä noudattava tietomalli ja raportti voidaan jakaa kaikenlaisia taustoja omaaville käyttäjille. Kun nimeämiset ovat kunnossa, niin datan ymmärtäminen helpottuu sekä mahdollisia datassa olevia virheellisiä rivejä huomataan pienemmällä vaivalla. Kunnolla nimetty tietomalli auttaa keskittymään itse sisältöön ja lukuihin, sen sijaan että keskittyminen menisi tietomallin toiminnan ja nimien ymmärtämiseen. Power BI -tietomallin nimeämisen lisäksi kannattaa kiinnittää erityistä huomiota oikein nimeämiseen jo tietokantatasolla. Tietokannassa hyvin nimetyt taulut mahdollistavat helpomman ratkaisujen monistamisen, joka taas mahdollistaa samoja lähdejärjestelmiä käyttävien ratkaisujen tuotteistamisen ja monistamisen, mikäli nimeämiset ovat lähdejärjestelmissä samoja. Hyvien sääntöjen ja yleisten käytäntöjen mukaan nimetty tietokanta helpottaa datan kaivamiseen liittyvää työtä.

3.6. Mallintamisen parhaat käytännöt

Power BI - ja SSAS-tietomallinnuksen parhaat käytännöt koostuvat useasta eri kategoriasta. Parhaiden käytäntöjen hyödyntäminen ja noudattaminen on pitkäjänteistä työtä mihin keskittyminen parantaa työn laatua ja oppimista. Kun parhaita käytäntöjä noudatetaan, on jatkossa seuraavien kehittäjien helpompaa palata tietomalleihin tekemään lisäyksiä ja muutoksia liiketoiminnan tarpeiden mukaan. Parhaiden käytäntöjen noudattamiseen ja seuraamiseen voidaan hyödyntää esimerkiksi Tabular Editoria. Parhaiden käytäntöjen sääntökokoomaa voidaan käyttää kaikkien VertiPac-pohjaisten mallien analysoimiseen, sisältäen Power BI Desktop-, Analysis Services-, Azure Analysis Services- ja Power BI Premiumissa sijaitsevat Tabular-mallit (Kovalsky, 2021b). SSAS-pohjaisiin Tabular-malleihin liittyvät vapaasti käytössä olevat GitHubista (Kovalsky, 2021a) löytyvät parhaat käytännöt voidaan luetella kuvan 21 tavalla.

Kategoria	Parhaiden käytäntöjen lukumäärä	Korjauslausekkeiden lukumäärä
DAX Expressions	10	0
Error Prevention	3	0
Formatting	15	8
Maintenance	9	5
Naming Conventions	2	1
Performance	23	2
Total	62	16

Kuva 21. GitHubin BPARules.json -tiedoston parhaat käytännöt analysoituna

Tarkastushetkellä joulukuussa 2021 Microsoftin ja yksittäisten kehittäjien lisäämiä parhaita käytäntöjä oli 62 kappaletta. Suurin osa säännöistä liittyy kategoriaan Performance. Suorituskykyyn vaikuttavia tarkastettavia sääntöjä löytyy tiedostosta 23 kappaletta. Kyseisessä kaikkien henkilöiden käytettävissä mutta Microsoftin hallinnoimassa avoimesti käytössä olevassa tiedostossa oli mukana 16 kappaletta automaattisia korjauslausekkeitä. Korjauslausekkeitä voidaan käyttää SSAS- ja Power BI -tietomalleissa olevien yksittäisten ongelmien automaattiseen korjaamiseen. Korjauslausekkeet muokkaavat taustalla olevan TOM-mallin tietoja C#-skriptin avulla (Kovalsky, 2021b). Parhaiden käytäntöjen tarkistus- ja korjauslausekkeet mahdollistavat usean ongelman samanaikaisen automaattiseen tunnistamisen. Osassa tilanteista parhaiden käytäntöjen vastaisten toimien korjaaminen on mahdollista napia painamalla. Jokainen sääntö pitää sisällään kategorian, kuvauksen, käytännön tason,


ongelmakohdat tunnistavan lausekkeen, ongelman vakavuustason välillä 1–3, ongelman nimen, ongelman kuvauksen ID:n, sekä yhteensopivuustason. Parhaat käytännöt ja korjaustoimenpiteet ovat tarkemmalle tasolle kuvailtuja sääntölausekkeita, jotka ovat C#-koodilla tehtyjä. Käytäntöjen avulla etsitään TOM-mallissa määritellyt asiat ja niille tehdään määritellyt tehtävissä olevat toimenpiteet, mikäli niin halutaan. Kuvasta 22 ilmenee esimerkinomaisesti, miltä lausekkeet ja korjauslausekkeet näyttävät kategorioittain ja nimittäin.

Kategoria	Nimi	Lauseke	Korjauslauseke
Formatting	[Formatting] Hide foreign keys	UsedInRelationships.Any (FromColumn.Name == current.Name and FromCardinality == "Many") and IsHidden == false	IsHidden = true
Formatting	[Formatting] Provide format string for "Date" columns	Name.IndexOf("Date", "OrdinalIgnoreCase") >= 0 and DataType = "DateTime" and FormatString <> "mm/dd/yyyy"	FormatString = "mm/dd/yyyy"
Maintenance	[Maintenance] Remove data sources not referenced by any partitions	UsedByPartitions.Count() == 0	Delete()
Maintenance	[Maintenance] Remove roles with no members	Members.Count() == 0	Delete()

Kuva 22. Esimerkki lausekkeesta ja korjauslausekkeesta nimittäin ja kategorioittain

Parhaiden käytäntöjen perustuminen ohjelmointiin mahdollistaa uusien parhaiden käytäntöjen lisäämisen omiin sääntökokoelmiin pienellä vaivalla. Tämä mahdollistaa esimerkiksi nimeämiskäytäntöjen tarkastelun eri maiden kielillä, sekä mahdollisten korjausten tekemisen bulkkina.

Ongelmia ja parhaita käytäntöjä voidaan tarkastella usealla eri tasolla. Taso kertoo, mihin ongelma ja sen ratkaisuun keskittyvä käytäntö ja ratkaisu liittyvät. Ongelma ja ratkaisu voivat liittyä tasoiltaan esimerkiksi laskennallisiin sarakkeisiin ja laskureihin. Kokonaisen listauksen tiedostosta löytyvistä tasoista ja niiden mainintojen määristä löytyy kuvasta 23.



Kuva 23. Parhaiden käytäntöjen laskennallisten tasojen mainintakerrat


Yksittäinen tarkasteltava käytäntö sisältää aina vähintään yhden tason, mutta käytäntö voi kuitenkin pitää sisällään useamman eri tason. Esimerkiksi “[Performance] Consider a star-schema instead of a snowflake architecture” -nimistä käytäntöä tarkastellessa katsotaan lauseketta taulu- ja laskennallinen taulu -tasoilla, koska molemmat liittyvät aiheiseen. Toisaalta taas kyseistä ongelmaa ei ole tarvetta tarkistella laskuritasolla, sillä ongelma ei liity millään tavalla laskureihin. Yleisellä tasolla voidaan katsoa, että parhaisiin käytäntöihin tutustuminen ja tietomallien kriittinen tarkastelu on hyödyllistä, helppoa ja vaivatonta.

4. Mallintamisen apuvälineet

Tässä luvussa käydään läpi valittujen teknologioiden mallintamiseen, kehittämiseen ja parhaiden käytäntöjen noudattamiseen liittyviä apuvälineitä sekä toimintatapoja. Neljännen luvun tarkoituksena on luoda taustaa käytössä olevista jokseenkin suosituiksi ja hyviksi luokitelluista apuvälineistä, niiden käyttötarkoituksista ja toimintatavoista. Apuvälineiden ja ohjelmoinnin katselmoinnin tarkoituksena on mahdollistaa parempi kehittäminen sekä helpottaa parhaiden käytäntöjen noudattamista. Tässä luvussa etsitään keinoja teknologisen velan vähentämiselle ja toimintatapojen parantamiselle.

4.1. Tabular Editor

Tabular Editor on Tabular-malleihin ja Power BI -tietomalleihin yhdistämisen mahdollistava työkalu, jonka avulla pystytään muuttamaan ja hallitsemaan laskureita, laskennallisia sarakkeita, näyttökansiota, perspektiivejä ja käännöksiä. Tabular Editorista on olemassa maksullinen yrityskäyttöön suunniteltu laajempi 3.x versio sekä ilmainen MIT-lisenssillä toimiva GitHubista ladattava 2.x versiot (Otykier, 2021). Kuvassa 24 näkyy Tabular Editor 2.16.4 käyttöliittymä. Tässä kappaleessa keskitytään ilmaisesti käytössä olevien 2.x mallien ominaisuuksiin.



Kuva 24. Tabular Editor 2.16.4 käyttöliittymä

Tabular Editor -ohjelmien toiminta perustuu TOM:n (Tabular Object Model) metadatan paljastamiseen ja muokkaamiseen. TOM paljastaa natiivin tabular-mallin metadatan kuten mallin, taulut, sarakkeet ja relaatio-objektit. (Owen, Coulter & Petersen, 2021) VertiPaaS pohjaisten tietomallien kehittämiseen tarkoitetuissa ohjelmissa on TOM:n pohjalle rakennettu käyttöliittymä. Käyttöliittymän avulla voidaan muokata tietoja jotka eivät ole muissa mallinnusohjelmissa käytössä. Tämä mahdollistaa muun muassa Power BI Desktopissa tehtävässä tietomallinnuksissa lisäominaisuuksien mukaan tuonin. Otykier (2021) luettelee ilmaisen Tabular Editorin päätoiminnallisuuksiksi seuraavat ominaisuudet:

1. TOM-objektien ja ominaisuuksien muokkaaminen
2. Tietojen editointi ja nimeäminen erissä
3. Tuki kopioi/liitä ja pudota/vedä toiminnallisuuksille
4. Kumoa ja tee uudelleen datan mallinnusoperaatioita


5. Mallin metatietojen tallennus levyille
6. Kansioon tallennus
7. Daxformatter.com integraatio (DAX-koodin formatointi automaattisesti parhaiden standardien mukaan helpommin luettavaan muotoon)
8. Kehittyneempi tietojen mallinnus (perspektiivit, laskentaryhmät, metatietojen käännökset, OLS (Object-level security))
9. Syntaksin korostus ja automaattinen kaavan korjaus
10. Objektien välisten DAX-riippuvuuksien tarkastelu
11. Import Table Wizard
12. Deployment Wizard
13. Best Practice Analyzer (parhaiden käytäntöjen analysointi- sekä korjaustyökalu)
14. C# skriptaus ja automaatio
15. Käyttö Power BI Desktop -kehityksen ulkoisena apu- ja työvälineenä
16. Yhdistäminen SSAS, Azure AS (Analysis Services) ja Power BI Premium malleihin
17. Komentorivikäyttöliittymä

Edellä mainitusta listasta löytyvät ominaisuudet ovat sellaisia, joita ei löydy Power BI Desktopista. Kyseiset käyttöön otettavat hyödyt ja ominaisuudet liittyvät Power BI -tietomallinnuksessa suoraan Tabular Editorin käyttämiseen. Tämän lisäksi yksi mainitsemisen arvoinen listauksen ulkopuolinen ominaisuus on muutosten tekeminen offline-tilassa. Tällöin TOM-malli ei prosessoi jatkuvasti kaikkia tehtyjä muutoksia, esimerkiksi laskurimuutosten tai kenttien formatoinnin ja datatyypin vaihdon jälkeen. Varsinkin suurien tietomallien kehittämisessä tästä saatavat ajalliset säästöt ovat suuria. Kokonaisuudessaan nämä ominaisuudet helpottavat ja nopeuttavat mallinnusta, sekä tekevät jo aiemmin opittujen käytäntöjen, kuten objektien välisten DAX-riippuvuuksien tarkastelusta nopeampaa. Power BI Desktopissa samoja objektien välisiä riippuvuuksia tarkastellessa tulisi avata jokainen laskuri ja laskennallinen sarakke erikseen ja kirjata riippuvaisuudet ylös. Tabular Editorin avulla tämä prosessi saadaan automatisoitua ja on helpoimmillaan yhden klikkauksen tai pikanäppäimen takana.

Best Practice Analyzeriä on syytä pitää maininnan arvoisena ominaisuutena, joka antaa mahdollisuuden 3.6. luvussa mainittujen parhaiden käytäntöjen ja virheiden osoittamiselle sekä automaattiselle korjaamiselle. Otykier (2021) kertoo verkkoartikkelissaan, että Tabular Editor kannattaa ottaa käyttöön kehittäjänä sen jälkeen, kun TOM-mallinnukseen liittyvät tekniikat ja konseptit kuten laskennalliset taulut ja sarakkeet, laskurit, relaatiot, DAX-koodaus ovat tulleet tutuksi. Tabular Editor ei kuitenkaan ole ratkaisu huonosta mallinnuksesta syntyneisiin ongelmiin. Apuvälineenä se tarjoaa kuitenkin mainittavan määrän konkreettisia keinoja nopeamman ja järkevämmän kehityksen mahdollistamiseksi. Samlla Tablar editor helpottaa myös tietomallien optimointia ja järkevöittämistä. Järkevöittämisellä voidaan tarjota esimerkiksi laskureiden siirtämistä oikeaan tauluun tai kansioon..

4.2. VertiPaq Analyzer

VertiPaq Analyzer on Dax Studioon versiosta 2.11.0 lähtien viralliseksi ominaisuudeksi integroitu lisäosa (Russo, 2021a), jonka avulla voidaan analysoida VertiPaq pohjaisten relaatiotietokantojen, kuten Power BI - ja SSAS Tabular -mallien kokoa ja rakennetta. VertiPaq on alkujaan SSAS Tabular -pohjaisten mallien DMV-pohjaisia (Dynamic Management View) metatietoja hyötykäyttävä Excel-pohjainen apuväline. VertiPaq Analyzer on tärkeä väline tietomallin sisällä olevien taulujen ja sarakkeiden kokojen analysointiin (Russo, 2021a). VertiPaq Analyzer on integroituna mukaan Tabular Editor 3.x ohjelmistoihin. DAX Studioon ja malliin yhteyttä luodessa käyttöliittymän ohjeiden mukaisesti päästään tarkistelemaan VertiPaq Analyzerin tietoja Advanced välilehdeltä painamalla ”View Metrics” painiketta. Painikkeen kohta näkyy kuvassa 25. Kuvassa näkyy alhaalla VertiPaq Analyzerin tuottama data.



Kuva 25. VertiPaq Analyzerin käyttöliittymä ja datasisältö

VertiPaq Analyzerin tiedot kertovat taulun koosta ja tiedoista bitteinä (B, bit). Yksittäisen taulun tiedot voi avata nuolimerkillä päästäkseen kiinni tarkempiin taulujen sisällä oleviin saraketasojen tietoihin. Taulukosta 4 löytyy selitteet sarakkeista, joista on jätetty tämän työn näkökulmasta mallinnuksen kannalta vähäisen merkityksen omaavat sarakkeet pois.

Taulukko 4. VertiPaq Analyzerin tables-välilehden sarakkeiden selitteitä. Kaikki koot ovat bittejä (B)

Nimi	Selite
Cardinality	Kardinaliteetti, Kertoo kuinka monta kertaa kyseisen sarakkeen arvot voivat liittyä toisen taulukon vastaaviin arvoihin.
Table Size	Taulun kaikkien sarakkeiden koko yhteenlaskettuna bitteinä sisältäen relaatioiden koon.
Col Size	Sarakkeiden ja sen datasisällön yhteinen koko bitteinä. Col Size on yhteenlaskettu summa kentistä Data, Dictionary ja Hier Size.
Data	Datasisällön koko.
Dictionary	Arvokirjaston koko.
Hier Size	Hierarkian koko.
Rel Size	Taulun relaatioiden vievä muistin koko. Relaatiot näkyvät vain taulutasolla yhtenä kokonaisuutena
% Table	Kuinka monta prosenttia taulusta kyseinen sarakke sisältöineen prosentteina.
% DB	Kertoo taulun tai sarakkeen koon prosentuaalisen osuuden koko tietokannan koosta

VertiPaqin automaattiset 2.6. kappaleessa mainitut datan kompressiot johdattavat noudattamaan tietomallien rakentamisessa parhaita käytäntöjä. Russo ja Ferrari (2015, s. 404)

kertovat kirjassaan, että pienempi ja täten nopeampi tietomalli on aina parempi skannauksen osalta. Tällöin VertiPac:n ei tarvitse skannata jokaista riviä ei tarvitse käydä lävitse erikseen. Kooltaan pienempi malli voi vähentää kustannuksia, kun tietomallien tallennukseen, prosessointiin, ja analysointiin ei mene niin paljoa muistia. Muistin pienempään käyttömäärään vaikuttaa tietomallin optimointi ja parhaiden käytäntöjen noudattaminen. Avainasemassa optimoinnissa on mallin koon minimointi ja siihen liittyvien toimenpiteiden toteuttaminen.

4.3. DAX Studio

DAX Studio on alun perin Darren Gosbellin kehittämä, mutta nykyään avoimen lähdekoodin projekti, joka on ilmainen Power BI Desktoptiin sekä SSAS Tabular-, Azure Analysis Services ja Power Pivot -malleihin käytettävä apuväline. DAX Studion avulla voidaan kirjoittaa, analysoida ja suorittaa DAX-kyselyitä. Ohjelma pitää sisällään kyselyjen editoinnin ja suorittamisen, objektselaimen, kaavojen ja laskureiden editoinnin, syntaksin korostamisen ja formatoinnin, integroidun seurannan ja kyselyiden suorittamisen analysoinnin sekä erittelyn. DAX Studio pitää sisällään edellisessä kappaleessa 4.2. mainitun VertiPac Analyzerin versiosta 2.11.0 alkaen (DAX Studio – SQLBI, 2021). DAX Studio (2021) nostaa verkkosivullaan mainitsemisen arvoiseksi tukemiksi ominaisuuksikseen taulukon 5 mukaiset ominaisuudet:

Taulukko 5. DAX Studion verkkosivuilta löytyvät ominaisuudet

Nimi	Selite
Useaan datalähteeseen yhdistäminen	DAX Studio on apuväline, jolla voit suorittaa DAX-kyselyitä seuraaviin tietolähteisiin: Power Pivot in Excel, Power BI Desktop / SSDT (Sql Server Data Tools) Integroidut työtilat, Analysis Services Tabular, Azure Analysis Services. DAX studio skannaa automaattisesti kaikki päällä olevat Power BI Desktop ja SSDT Integroidut työtila -instanssit koneeltasi
Integroitu DaxFormatter tuki	Sovelluksesta löytyy integroitu tuki DaxFormatter.com -verkkosivulle, joka auttaa sinua muotoilemaan automaattisesti DAX-koodisi helpommin luettavaan muotoon.
Palvelimien ajoituksen jäljitys	Ohjelmalla voidaan kerätä kyselyiden suorittamisen dataa, joka auttaa performanssin parantamiseen. Tämä voi olla hyvä keino muun muassa havaitakseen kahden samoja lukuja tuottavan ja näennäisesti saman tuloksen tuovan laskurin todellisen eron apuvälineen näyttäessä dataa suorituskyvystä.
Erottimien vaihto	DAX koodissa käytetään valtiosta riippumatta eri erottumia. US-kielellä käytetään pilkkua (,) luetteloiden kohteille ja pistettä (.) desimaalierottimelle. Eurooppalaisessa versiossa taas käytetään puolipistettä (;) luettelon kohteille ja pilkkua (,) desimaalierottimelle. Tämänkaltaisuus on hyödyllistä, sillä Power BI -raporttien käytössä olevat erottimet ovat aina raporttikohtaisia riippuen lokalisaatioasetuksista.

DAX Studio sisältää jonkin verran samoja ominaisuuksia kuin Tabular Editor. Esimerkki tästä on integroitu DaxFormatter-tuki. DAX Studio on Microsoftin verkkosivujen opaskirjan (Microsoft, 2021c) mukaan monipuolinen DAX:n hallintaan, diagnosointiin, suorituskyvyn hienosäätämiseen ja analysointiin tarkoitettu työkalu, jonka ominaisuuksiin kuuluu objektien selaus ja jäljitys, kyselyiden suorittamisen erittelyt yksityiskohtaisilla tilastoilla sekä DAX-syntaksin korostus ja muotoilu. DAX Studion päällekkäisyydet muiden ohjelmien kanssa eivät kuitenkaan tee DAX Studiosta vertailukelpoista muiden apuvälineiden kanssa. DAX Studio keskittyy pohjaltaan eri osa-alueisiin kuten kuin muut diplomityössä mainitut apuohjelmat.

4.4. Ohjelmoinnin katselmointi

Ohjelmistojen katselmointi ja tarkistus on laajalti tunnistettu tärkeäksi menetelmäksi ohjelmistojen kehittämisessä (Kollanus, 2011). Ohjelmiston katselmointia käytetään ohjelmiston, dokumenttien ja muiden tuotettujen artefaktien laadun parantamisen apuvälineenä kehityksen aikana (Kollanus & Koskinen, 2009, s.1). Tarkistuslistat ovat yksi useimmiten käytetty metodi virheiden löytämiseen. Tarkistuslistat sisältävät asiantuntijoiden koostamia usein kohdattujen ongelmia, ja näin ne tukevat ohjelmistojen katselmointia (Kollanus & Koskinen, 2009, s. 22). Tämänkaltaisten tarkastuslistojen voidaan todeta helpottavan ohjelmistojen aktiivista katselmointia. Näillä perusteilla voidaan katsoa, että Power BI:n parhaiden käytäntöjen hakeminen Tabular Editoriin ja näiden käyttäminen ohjelmiston kehittämisen aikana on laatua parantava tekijä, mikäli maininnat huomioidaan ja niihin reagoidaan. Tabular Editoria ja Microsoftin hallinnoimia parhaita käytäntöjä hyödyntämällä voidaan aktiivisesti tehdä tarkistuksia siitä, miten mallinnuksessa on suoriuduttu.

Eisty Nasir ja Carver Jeffrey (2021, s.19) mainitsevat katselmointia tutkivassa vertaisarviointia käsittelevässä artikkelissaan kehittäjien kokevan suurimmiksi ongelmikseen vertaisarvioinnin vievän liian suuren ajankäytön, kommenttien muotoilun, äänensävyyn puutteen tekstissä, oikeiden ihmisten löytämisen vertaisarvioinnin suorittamiseen, osallistumisen ja kehittäjien itsetunnon. Samalla ohjelmistokehittäjät kertoivat näiden ongelmien ratkaisemisen parhaimmiksi todetuiksi keinoiksi prosessien virallistamisen, apuvälineiden käytön, työntekijöiden lisäämisen vertaisarviointiin, kannustimien mukaan ottamisen, koulutuksen, työajan varaamisen katselmointiin ja nopeamman vertaisarvioinnin vastaussyklin. Giuliana Carullo (2020, s.168) mainitsee kirjassaan, että kehittäjän osalta koodikatselmuksia tehdessä

on tärkeää muistaa, että vertaisarviointia toteutettaessa katselmoinnista ei tehdä tuomitsevaa tai henkilökohtaista. Kyseessä on ratkaisujen arvostelu, ei työntekijöiden.

Eisty Nasirin ja Jeffrey Carverin artikkelin mukaan (2021, s.17–18) 77 vastaajaa 84 vastaajasta kertoi, että vertaisarvioinnin koetaan parantavan koodin laatua huomattavasti. Kyseiset 77 vastaajaa antoivat syiksi koodin oikeellisuuden, paremman luettavuuden, useamman silmäparin tarkastelun, paremman ylläpidettävyyden, paremman suunnittelun, osaamisen jakamisen, reliabiliteetin parantamisen, paremman koodin muotoilun sekä parantuneen dokumentoinnin.

Power BI -ratkaisuihin liittyvissä ohjelmoinnin katselmoinneissa voidaan ottaa käyttöön ohjelmistomaailmassa todettuja hyviä käytäntöjä. Toimintatavat ja periaatteet toimivat useimmiten samalla tavalla, vaikka taustalla oleva katselmoinnin kohteena oleva teknologia olisi eri. Yleisesti katsoen voidaan ajatella, että vähintään kahden ihmisen kannattaisi perehtyä aina jokaiseen raporttiin ja tietomalliin. Kaksi ihmistä huomaa todennäköisemmin paremmin mallista löytyviä virheitä kuin yksi ihminen. Tällöin katselmoinnin aikana saadaan huomautettua toisia tekijöitä saman asian toteuttamisesta järkevämällä tavalla, harvemmin kehittäjät haluavat käyttää useaa tuntia tehtävään, jonka saisi hoidettua nopeammin. Samaa mieltä ovat varmasti myös kehittäjien asiakasryhmät. Ohjeita ja vinkkejä kannattaa kysyä aina aktiivisesti joko organisaation sisältä tai mahdollisesti konsulteilta. Katselmoinnin aikana virheitä ja ongelmia käsiteltäessä yhdessä saadaan jaettua tietoa eteenpäin sekä mainittua muista käytäntöihin ja mallin ongelmiin liittyvistä asioista. Mallin epäoptimaalisuuteen liittyvät asiat kannattaa kuitenkin hoitaa asiallisesti ja samalla tehdä selväksi, että kyseessä ei ole henkilökohtainen arviointi.

Aktiiviseen käyttöön katselmointiin tulisi ottaa myös kehityksessä käytettäviä apuvälineitä kuten Tabular Editor ja siihen liittyvät Microsoftin ylläpitämät parhaat käytännöt. Tällöin Best Practice Analyzerin avulla kehittäjä saa palautetta toimintatavoistaan ja mahdollisista huomiota ansaitsevista ongelmista, sekä mahdollistaa tietomallin paremman esittämisen katselmoijalle. Vertaisarvioinnit olisivat hyödyllistä käydä projektien valmistumisen jälkeen apuvälineitä hyödyntäen. Arviointien lisäksi olisi hyvä käydä läpi mitä projekteista on opittu. Samalla kyseisiä ratkaisuja voidaan esittää muille kehittäjille, jolloin voidaan kertoa oudolta vaikuttavien ratkaisujen pohjasyitä. Kokonaisuudessaan lähtökohtana ohjelmoinnin katselmoinnille BI-maailmassa on projektin jälkeen alkuperäisiin määrittelyihin palaaminen, sekä parhaiden käytäntöjen vastaisten toimien korjaamisen lisääminen aktiiviseen päivittäiseen

työskentelyyn. Samalla nimeämiskäytäntöihin kannattaa kiinnittää erityistä huomiota jo alusta saakka. Tämän takia nimeämiskäytäntöjä olisi hyvä lisätä organisaation valitsemien käytäntöjen mukaan parhaiden käytäntöjen listaan, jos tämänkaltaiset käytännöt ovat olemassa. Nimeämiskäytäntöjä olisi tärkeää miettiä jo ennen kehityksen aloittamista, mutta viimeistään ennen tuotantoon siirtymistä. Kehitysvaiheessa nimiin voidaan vaikuttaa helposti eikä niiden muuttaminen aiheuta teknisiä ongelmia mahdollisille tietomallien loppukäyttäjille. Nimeämiskäytäntöihin on järkevää puuttua vain silloin kun niihin puuttuminen ei aiheuta lisää ongelmia.

5. Mallintaminen


Mallintamista käsittelevässä luvussa käydään läpi teoriaosuuden kertomia hyötyjä mallintamisen näkökulmasta. Mallintamisessa keskitytään määrittelyyn, jatkuvan kehittämisen toimintatapoihin ja tukitoimintoihin sekä muihin tiedon mallintamiseen liittyviin huomioihin. Viidennessä luvusta ei löydy tarkkoja ohjeita siihen, miten käytännön implementointi toteutetaan valituilla apuvälineillä ja teoriakokonaisuuksilla. Mallintamista käsittelevissä kappaleissa keskitytään ohjeiden sijaan antamaan syitä miksi ja millä keinoin näitä käytäntöjä kannattaa toteuttaa.

5.1. Tehtyjen tietomallien kehitystyöt

Tehtyjen ja toteutettujen raporttien sekä tietomallien optimoinnissa ja kehittämisessä tulee ottaa huomioon tietomallin rakenne. Tämän kappaleen esimerkeissä käytetään kehitystyön ja mallintamisen merkitystä helpottamiseksi esimerkkiä, jossa tietomalli on yksittäinen Power BI:ssä tehty ja Power BI Serviceen jaettu raportti. Käyttäessä tämänkaltaista esimerkkiä ei tarvitse huolehtia mahdolliseen itsepalveluraportointiin liittyvistä yhteyksistä. Kappaleessa jätetään huomioimatta tietomallien uudelleen käytön luovat mahdolliset ongelmat. Suurimmat ongelmat Power BI -tietomallien ratkaisussa johtuvat usein tietomallin puutteellisuudesta kehittämisestä ja sen usean faktataulun osittain denormalisoidusta, normalisoidusta ja sekavasta rakenteesta. Tietomallin ja ratkaisun kokonaan uudelleen rakentaminen useamman vuoden jälkeen on harvemmin reaali maailmassa toteutettavissa oleva ratkaisu. Tällöin tekniseen velan pienentämiseen vaaditaan muita ratkaisuja.


Power BI -tietomallien parantaminen ja optimointi liittyvät vahvasti tietomallin ylläpidettävyyden, performanssin, muotoilun ja DAX-koodin selkeyden parantamiseen. Kyseisiä ongelmia voidaan välttää hyödyntämällä kehityksen aikana Tabular Editorin Best Practice Analyzeria mutta jälkikäteen tapahtuva analysointi on mahdollista ja suositeltavaa, mikäli raportilla on käytettävyyso ongelmia ja jatkokehitystä on tarkoitus toteuttaa tulevaisuudessa. DAX-koodin formatointi mahdollisesta heikommin muotoillusta koodista auttaa

hahmottamaan koodia paremmin muotoilun avulla, kuten kuvasta 26 ilmenee. Kuvassa käytetty DAX-koodi on pseudokoodia.



Kuva 26. Esimerkki Tabular Editorissa muotoillusta DAX-koodista

Avaamalla Tabular Editor -ohjelman ja käyttämällä hyödyksi parhaiden käytäntöjen tietoja saadaan näkyviin ratkaisutoimenpiteet, joiden avulla kyetään parantamaan tietomallien ylläpidettävyyttä, suorituskykyä, muotoilua ja DAX-koodin selkeyttä. Avattuasi tietomallin ja ladattuasi mukaan parhaat käytännöt (liite 2) pääset tarkastelemaan ongelmia ja korjaamaan vastaavat. Best Practice Analyzerin esiin nostamia parhaiden käytäntöjen vastaisia toimia voidaan korjata automaattisesti. Automaattisen korjauksen mahdollisuus näkyy klikkaamalla hiiren oikealla ongelman päällä. Esimerkki yhden kategorian automaattisista korjauksista näkyy kuvassa 27.



Kuva 27. Esimerkki Tabular Editorin automaattisista tietomallin korjauksista

Esimerkkinä käytettiin Diplomityön tekijän aiemmin luomaa Power BI -raporttia, joka sisältää Suomen valtion avointa dataa konkurssiin menneihin yrityksiä, sekä kuluttajahintaindeksistä ja ansiotasoista. Yksittäisen raportin relevantit ongelmat kyettiin käymään läpi alle 30 minuutissa. Tabular Editorin opasti hyvin korjaamaan ongelmat, joihin ei ollut tarjolla automaattisia korjauksia. Alun 109:stä huomattua parhaiden käytäntöjen vastaisista ongelmista saatiin ratkaistua Tabular Editorin avulla 53 kappaletta, ja jäljelle jäi täten 56 kappaletta huomiotta jätettyjä ongelmia. Huomiotta jätetyt ongelmat sisälsivät muun muassa objektien kuten taulujen, laskurien ja sarakkeiden kuvailuja, joita ei koettu tässä tapauksessa tarpeellisiksi. Verrattessa vanhaa optimoimatonta tietomallia uuteen optimoituun tietomalliin VertiPaq Analyzerilla huomattiin mallin koon pienentyneen. Suurin osa tietomallin pienennyksestä johtui käyttämättömien taulujen ja kolumnien poistosta, sekä performanssiin liittyvistä korjauksista. Tässä esimerkissä käyttämättömät taulut ja kolumnit olivat Power BI:n automaattisesti luomia aikadimensiotauluja (1 kpl tässä mallissa), jotka eivät olleet tarpeellisia tietomalliin liitetyn aikataulun vuoksi. Tietomallin koko kuitenkin puolittui ja muuttui näillä muutoksilla alkuperäisestä 2,56 MB:stä 1,15 MB:seen, kuten kuvasta 28 ilmenee.

Tietomalli ennen muutoksia



Kuluttaja- ja ansiohintaindeksi.pbix

Total Size	Last Data Refresh	Analysis Date
2,56 MB ⓘ	3.1.2022 22.05.22 +02:00	19.1.2022 12.57.19 +02:00
Compatibility	Tables	Columns
1550	8	50
		Server
		localhost:51628

Tietomalli muutosten jälkeen



Kuluttaja- ja ansiohintaindeksi.pbix

Total Size	Last Data Refresh	Analysis Date
1,15 MB ⓘ	19.1.2022 12.52.59 +02:00	19.1.2022 13.10.07 +02:00
Compatibility	Tables	Columns
1550	6	34
		Server
		localhost:51261

Kuva 28. DAX Studion VertiPaq Analyzerin kooste tietomallista

Tehtyjen tietomallien optimointi ja muutokset voidaankin todeta suhteellisen vaivattomiksi, varsinkin jos versionhallinta on kunnossa ja vanhoihin tietomalleihin voidaan palata ongelmien ilmetessä. Tällöin ei tarvitse huolehtia tehtyjen muutosten vaikutuksista ratkaisujen toimivuuteen, myöskään mahdollisesti sellaisissa tapauksissa, jossa kyseistä Power BI Service -portaaliin vietyä tietomallia käytetään uudelleen itsepalveluraportoinnissa. Itse mallin parhaisiin käytäntöjen noudattamiseen liittyvät nopeat korjaukset ovat helppoja tehdä Tabular Editoria hyödyntämällä, mutta suuremmat malliin tehtävät muutokset voivat aiheuttaa ongelmia olemassa oleviin tietomalleihin ja siitä johdettaviin raportteihin. Tietomalliin tehtävät suuremmat muutokset kuten kenttien poistot, taulujen poistot ja yhteyksien muokkaukset ovat aina riskaabeleja vaihtoehtoja, joiden vaikutusta on vaikea arvioida ilman tarkkaa testaamista. Suurimmat ongelmat luovat kuitenkin tässä tapauksessa puutteellinen arkkitehtuuri sekä tietomallin kehittämisvaiheessa tehtyt virheet, joita ei voida enää mallien tai raporttien pitkälle menneen jalostuksen takia muuttaa. Arkkitehtuurillisiin ongelmiin voidaan hakea ratkaisuja parhaiten toimintatapoja muuttamalla. Organisaatiotasolla on tärkeä

hyväksyä ymmärrys niiden tietomallien suhteen, joille on jatkossa promootio ja sertifioinnin avulla myönnetty jatkuvan kehityksen tuki muiden osapuolien toteuttamiin itsepalveluratkaisujen tarkoituksiin.

5.2. Uusien raportti- ja tietomallikokonaisuuksien määrittely

Uusien tietomallien ja raporttien kehittäminen lähtee usein käyntiin raporttivaatimusten keräämisellä ja määrittelyllä. Raportin määrittely ja vaatimusten kerääminen on tärkeä osa kehittämistä, ja se vaikuttaa huomattavasti tietomallin kehittämiseen. Hyvin tehtyjen määrittelyjen avulla autetaan kehittäjää ja tuotteen omistajaa päivittäisessä työssään. Määrittelyyn kuuluu raporttivaatimusten ja tietovaatimusten kerääminen. Nämä kaksi vaihetta liittyvät tarkasti toisiinsa ja raporttivaatimukset auttavat vähentämään teknistä velkaa sekä ymmärtämään tietovaatimuksia paremmin. Näitä asioita on hyvä käsitellä yhtenäisenä kokonaisuutena. Määrittelytietoja kerätessä on suositeltavaa luokitella ominaisuuksia niiden tärkeyden perusteella. Raporttivaatimuksia voidaan kerätä esimerkiksi taulukossa 6 mainituista asioista.

Taulukko 6. Microsoftin esimerkit kerättävistä raporttivaatimuksista (Microsoft, 2022c)

Raporttivaatimus	Selite
Tarkoitus, kohderyhmä ja odotettu toiminto	Selvitä raporttien tarkoitus ja liiketoimintaprosessit, sekä kohdeyleisö, joille raportti on tarkoitettu. Selvitä raportin odotetut toimet, jota käyttäjät on tarkoitus pystyä tekemään.
Miten kuluttajat käyttävät raporttia	Käy lävitse, miten olemassa olevia raportteja käytetään. Tätä kautta voidaan oppia mitkä raporttien elementit ovat turhia, ja mitä voidaan tuoda mukaan uusiin ratkaisuihin.
Omistaja ja aihealueen asiantuntija	Selvitä raportin omistaja ja tietomallin toimialueeseen liittyvät asiantuntijat organisaatiossa. Selvitä miten raportille tehtäviä muutospyyntöjä käsitellään. Kaikkiin muutoksiin ei tarvitse raportin omistajan lupaa.
Sisällön toimitustapa	Tee selväksi, miten raportin kuluttajat haluavat tiedon itselleen käyttöön. Käyttötapoja on useita.
Vuorovaikutteisuustarpeet	Selvitä raportin pakolliset ja ”nämä olisivat kiva saada” vuorovaikutusvaatimukset, kuten suodattimet ja porautumistoiminnot.
Tietolähteet	Varmista, että kaikki raportin toteuttamiseen vaadittavat tietolähteet löydetään, ja että datan viiveen (tietojen tuoreus) ymmärretään. Tunnista kunkin raportin historialliset tiedot, trendit ja tietojen tilannevedoksen vaatimukset, jotta ne voidaan kohdistaa yhteen tietovaatimusten kanssa. Tietolähdettä koskevat ohjeet voivat olla hyödyllisiä myöhemmin uusia kokonaisuuksia kehittäessä.
Suojausvaatimukset	Selvitä ketkä saavat katsella ja muokata raportteja, sekä selvitä rivitason suojaustarpeet. Ota huomioon, jos tehdään poikkeuksia organisaation normaaliin suojaukseen. Dokumentoi mahdollinen tietojen luottamuksellisuustaso, tietosuoja tai sääntely- ja yhteensopivuustarpeet.
Laskutoimitukset, suorituskykyilmaisimet ja liiketoimintasäännöt	Tunnista ja dokumentoi kaikki tällä hetkellä käytetyt laskutoimitukset, suorituskykyilmaisimet (KPI) ja liiketoimintasäännöt, joita on käytetty aiemmin.
Käytettävyys-, asettelu- ja kosmeettiset vaatimukset	Tunnista tietojen visualisointien, ryhmittelyn ja lajittelun vaatimuksiin ja ehdolliseen näkyvyyteen liittyvät erityiset käytettävyys-, asettelu- ja kosmeettiset tarpeet. Selvitä mahdolliset mobiiliraporttien käyttöön liittyvät tarpeet.
Tulostus- ja vientitarpeet	Selvitä sopivin raporttityyppi ja onko raportin tulostamiselle tarvetta. Kannattaa kuitenkin rohkeasti tehdä kehotuksia toimintatapojen parantamiseen. Ota huomioon se, että raporttien käyttäjät mielellään tekevät asiat samalla tavalla kuin aieminkin.
Riskit ja huolenaiheet	Selvitä onko raporteille muita teknisiä tai toiminnallisia vaatimuksia sekä mahdollisia riskejä tai huolenaiheita, jotka koskevat niissä esitettyjä tietoja.
Avoimet ongelmat ja keskeneräiset työt	Tunnista mahdolliset tulevat ylläpitotoimet, jatkuvan kehityksen toimet, tunnetut ongelmat tai lykätty pyynnöt, jotka lisätään keskeneräisten töiden joukkoon.

Raporttivaatimuksia kerätessä on myös suotavaa kerätä listaus tietovaatimuksista. Tietovaatimusten keräämisellä mahdollistetaan raportin käyttötarkoitusten toteuttaminen sekä kehittämisen helpottaminen. Samalla saadaan luotua hyödyllistä dokumentaatiota jatkokehittämistä varten sekä jalostettua mahdollisia käyttötarkoituksia kuten tietomallien uudelleen käytettävyyttä jaettujen tietojoukkojen avulla. 2.2. kappaleessa mainitun teoriaosuuden mukaisesti kyseiset tietojoukot voidaan sertifioida. Tietojoukkoja sertifioidessa kannattaa

kuitenkin miettiä ovatko ne organisaation laatustandardien mukaisia. Sertifioinnin avulla ilmaistaan datan luotettavuus ja parannetaan sen löytämistä. Tietovaatimuksia kerätessä voidaan käyttää hyödyksi taulukkoa 7.

Taulukko 7. Microsoftin esimerkit selvitetävistä tietovaatimuksista (Microsoft, 2022c)

Tietovaatimus	Selite
Aiemmin luodut kyselyt	Selvitä löytyykö aihealuetta käsitteleviä raporttikyselyitä tai tallennettuja toimintasarjoja, joita voidaan käyttää hyödyksi raporttia kehittäessä. Tämänkaltaiset ratkaisut ovat usein DirectQuery- tai yhdistelmämallia. Samalla kyseessä voi olla Power BI -palveluun jaettu tietojoukko tai -malli.
Tietolähdetyypit	Kokoa kaikki tietolähteet listaksi, jotka ovat tarpeellisia raportin- ja tietomallin kehittämistä varten. Näitä voivat olla keksitetyt ratkaisut kuten tietovarastot, tai esimerkiksi standardinvastaiset Excel-tiedostot. Tietolähteiden ja tiedon selvittäminen on tärkeää yhdyskäytävän liitettävyyttä varten
Tietorakenne ja siistimistarpeet	Selvitä tietolähteiden datan rakenne ja missä määrin tietoja tarvitsee siistiä käyttöä varten.
Tietojen integrointi	Arvioi miten datan integrointia käsitellään, kun tietolähteitä on useita. Arvioi miten relaatiot voidaan luoda taulukkojen välillä. Pyri ymmärtämään toimintatavat, joilla mallin luettavuutta voidaan yksinkertaistaa, sekä kokoa pienentää.
Hyväksyttävä tietojen viive	Selvitä datan viiveiden tarpeet tietolähteille. Tietolähteiden viiveiden tarpeet vaikuttavat raporttien päivytystaajuuteen. On tärkeää tietää milloin lähdejärjestelmät päivittyvät ja kuinka usein raportteja halutaan päivittää.
Tietojen määrä ja skaalattavuus	Arvioi olemassa olevaa ja etenkin tulevaa datan määrää ja datan odotuksia. On tärkeää tietää kuinka skaalattava kyseinen tietomalli voi olla, ja että tuleeko tulevaisuudessa ongelmia datan määrän ja päivitysten suhteen.
Mittarit, suorituskykyilmaisimet ja liiketoimintasäännöt	Mieti tarpeet mittareille, suorituskykyilmaisimille (KPI) ja liiketoimintasäännöille. Nämä asiat vaikuttavat siihen missä logiikkaa käytetään. Onko logiikka tietojoukossa, raportilla vai integroinnissa.
Ydintiedot ja tietohakemisto	Mieti onko tärkeimpiin ydintietoihin liittyviä ongelmia, jotka edellyttävät huomiota. Selvitä onko data katalogin käyttö tarpeellista, jotta voidaan parantaa datan löydettävyyttä sekä käyttää määritelmiä ja tuottaa organisaation hyväksymiä yhdenmukaisia termejä.
Suojaus ja tietosuoja	Määritä onko tietojoukoille suojaus- tai tietosuojaseikkoja, kuten rivitason suojausvaatimuksia.
Avoimet ongelmat ja keskeneräiset työt	Lisää tunnetut ongelmat, tietojen laatuun liittyvät puutteet, tulevat ylläpitotoimet tai lykätty pyynnöt ja mahdolliset riskit keskeneräisten töiden joukkoon.

Määrittelyvaiheessa pidetyn aloituspalaverin jälkeen kannattaa palata myöhemmin määrittelyssä esiin nousseisiin asioihin. Sopiva aika voi esimerkiksi 2–3 viikon kuluttua määrittelyjen keräämisestä, mikäli aikataulut mahdollistavat tämän. Asioita kannattaa palata käsittelemään myöhemmin, sillä projektien edetessä ymmärrys kokonaisuudesta kasvaa. Usein kokonaisuutta koskevia asioita ja lisäkysymyksiä tulee mieleen myös myöhemmin. Järkevänä toimintatapana on pidetty myös määrittelytietojen siistiminen asiaan palatessa. Tietomallien

järkevä ja kunnollinen kehittäminen vaatii hyvin tehdyn määrittelyn, jossa useita mahdollisia käyttötarpeita on otettu huomioon.

5.3. Uusien tietomallien kehittäminen

Uusien tietomallien ja raporttien kehittämisessä on järkevää lähteä liikkeelle määrittelyjen jälkeen rakentamalla kokonaiskuva rakennettavasta tietomallista. Hyvien tietomallien kehittäminen perustuu pohjimmiltaan hyviin määrittelyihin, dimensionaalisen mallinnukseen, tähtimalliin ja DAX-koodauksen ymmärtämiseen. Tärkeänä osana tietomallien kehittämistä voidaan pitää useamman faktataulun käyttöä ja header- sekä detail -taulujen toimintatapojen ja ominaisuuksien ymmärtämistä. Samalla tulee ymmärtää, miten relaatioita voidaan rakentaa sekä miten taustalla oleva pakkauksen toteuttava VertiPac moottori toimii. Yleisesti uusia tietomalleja kehittäessä apuvälineiden kuten Tabular Editorin käyttö auttaa huomaamaan jo kehitysvaiheessa tietomallinnuksessa tehdyt virheet. Best Practice Analyzerin käyttö auttaa kehittäjiä sekä itsepalveluraportoinnin käyttäjiä muistuttamaan mallinnuksesta toteutettavissa olevista parhaista käytännöistä, sekä välttämään aktiivisesti virheitä.

Diplomityöntekijän vuosien alan työkokemukseen ja muiden kehittäjien kanssa keskusteluun sekä verkosta löytyviin artikkeleihin ajatuksia peilaten voidaan katsoa, että yksittäisiä oikeita toimintatapoja uusien tietomallien ja raporttien kehittämiseksi ei ole. Kehittäjiä voidaan kuitenkin opastaa pienellä vaivalla toimimaan parempien ja parempien tapojen mukaisesti. Työn tekijän tärkeimpänä pitämä perusta sarakepohjaisten Power BI ja Tabular-mallien paremmalle kehitykselle on teknologisen taustan ymmärtäminen sekä yleisien ja helposti huomattavien virhekohtien välttäminen. Virhekohtien välttäminen tapahtuu pohjimmiltaan samalla tavalla niin uusien kuin vanhempienkin tietomallien kehittämisessä. Tehdyt virheet ovat kuitenkin helpompia välttää, kun ratkaisut eivät ole vielä tuotantokäytössä. Jälkikäteen tehtävät pienetkin raportti- ja tietomallitekniset muutokset voivat olla laajojen liitännäisyyksien takia hyvin hankalia ja työläitä toteuttaa.

Kunnollisella kehityksellä minimoidaan teknisen velan määrää. Tähtimallin valitseminen dimensionaaliseksi mallinnusmuodoksi, relaatioiden muutokset sekä useamman faktataulun ratkaisujen tietomallintamisen muutokset ovat usein vaikeita ja lähes mahdottomia toteuttaa järkevällä työmäärällä, kun ratkaisut ovat jo tuotantokäytössä. Jokainen vasten parhaita käytäntöjä tehty toimenpide ja päätös heikentää tietomallin toimintakykyä ja tulevaisuuden kehittämistä. Tietomallin toimintakyvyn heikkous säteilee niin tietomallin lukemiseen,

käyttöön, teknologiseen toimimiseen, nopeuteen, päivityssykliin, dokumentaatioon kuin it-sepalvelukäyttöönkin. Samalla raporteissa on usein huonoista tietomallipäätöksistä johtuvia hitauksia.

Power BI:llä saadaan helposti näyttäviä ja toimivia tuloksia aikaan mutta yhtenä suurena heikkoutena tuotteessa on sen helppokäyttöisyys. Helppojen tulosten aikaansaaminen saat-taa aiheuttaa epäoptimaalisia tuloksia, kun teknistä osaamista ja ymmärrystä ei ole taustalla. Tästä-syystä uusia tietomalleja kehittäessä on tärkeää ymmärtää, minkälaiseen tarkoitukseen tietomallia ja raporttia halutaan kehittää. Branscomben (2021) teknologiaan ja IT:seen pe-rehtyvän CIO-lehteen kirjoitetun artikkelin mukaan työntekijöitä ei kannata jättää yksin ke-hitykseen liittyvissä asioissa. Tällöin voidaan aiheuttaa kokonaisarkkitehtuurillisesti hallit-sematon tilanne. Hallitsemattomaan tilanteeseen auttaa ratkaisujen hyväksymisen hallinta, sekä tietomallien ylös nostaminen ja sertifiointi hyvien datamallien ylös nostamiseksi. Ke-hittämisvaiheessa ei tule unohtaa vanhempien osaajien tarjoamaa tukea ongelmiin sekä ak-tiivista palautteen antamista kehittämisen osalta. Yhtenä tärkeänä osuutena voidaan pitää koulutuksia, joissa vuorovaikutuksen avulla saadaan jaettua osaamista organisaation sisällä. Microsoft pitää hyödyllisenä keinona perustaa BI:n ja analytiikan ammattilaisista koostuvan tiimin, joka on vastuussa BI-ympäristön luomisesta ja ylläpidosta. Tärkeänä ominaisuutena tämän kaltaisen tiimin luomisessa on se, että yrityksen sisällä saadaan luotua vankka ympä-ristö, joka tarjoaa oikeat tiedot oikeille henkilöille oikeaan aikaan, samalla tiedonkulkua, koulutusta ja tukea kehittäen. (Microsoft, 2022a).

Täydellisen listan toteuttaminen liittyen uusien tietomallien kehittämiseen on hyvin vaikeaa. Tutkimuksen aikana uusien tietomallien kehittämisessä huomioon asioista löytyy seuraa-vasta listasta:

- Hoida määrittely kunnolla. Hyvin tehty määrittely mahdollistaa kunnollisen kehittä-misen, sekä arkkitehtuurin kannalta olemassa olevien ja tulevien ominaisuuksien ja käyttökohteiden huomioon ottamisen. Ohjeet hyvin tehtyyn määrittelyyn saat esim. kappaleesta 5.2.
- Valitse dimensionaaliseksi mallinnusmuodoksi aina tähtimalli sen ollessa mahdol-lista. VertiPaq pohjaiset tietomallit ovat parhaimpia dimensionaalisille tietomalleille, joista paras näihin Power BI- ja SSAS-käyttötarkoituksiin on tähtimalli.

- Litistä header- ja detail-tasojen taulut sekä dimensiohierarkiat yksittäisiksi tauluiksi tai näkymiksi.
- Useamman faktataulun ratkaisut tulee suunnitella tarkemmin. Mieti tarkkaan, minkä dimensioiden avulla saadaan yhdistettyä data toisiinsa, ja mitkä kolumnit olisivat syytä denormalisoida faktatauluihin. Useamman faktataulun ratkaisut vaikeuttavat jatkokehitystä, ja tästä syystä niitä tulisivatkin välttää. Yksittäistä oikeaa ratkaisua ei olemassa.
- Ota hyvät nimeämiskäytännöt käyttöön. mieti mallin kokonaisuutta ja mitä ratkaisuja on jo olemassa mallia rakentaessa. Taulukosta 3 löytyy lisää asiaa tähän liittyen. Kunnolla tehty nimeäminen niin tietovarastoihin kuin raportteihin ja tietomalleihin-kin mahdollistaa samoista lähdejärjestelmistä tulevien ratkaisujen tuotteistamisen
- Mieti semanttista tietomallirakennetta, kuinka hyvä tietomalli tietovarastossa on olemassa. Ideaalitulanteessa mallit saadaan käyttöön miltei suoraan tietovarastosta
- Suosi suoria näkymiä joiden avulla data ladataan tietomalliin. On järkevämpää tehdä ”SELECT * FROM VIEW_FACT_TABLE” -kysely, joka mahdollistaa VertiPaq moottorin järkevämmän käsittelyn. Tällöin käsittelysäännöt ovat alemmalla tasolla, jolloin niitä voidaan käyttää hyödyksi muuallakin. Tämä nopeuttaa Power BI -prosessointia
- Ota malliin mukaan tietoa vain mahdollisimman pienellä kardinaliteetilla. SSAS ja Power BI -tietomalleilla on valtava merkitys siinä, onko data kuinka yksilöivää. Tarpeettoman yksilöivällä ja tarkalla tasolla olevat sarakkeet ja rivit jotka eivät ole tietomallissa käytössä heikentävät suorituskykyä. Yksittäisten rivien uniikkia määrää eli kardinaliteettia nostavat rivit ovat VertiPaq-moottorin avulla toimiville tietomalleille käytettävyyden kannalta huonoja
- Poista tietomallista kaikki sarakkeet, jotka eivät ole käytössä. Tabular Editorin BPA:n avulla voidaan poistaa automaattisesti piilotetut sarakkeet, joihin ei viitata tietomallissa missään. Käyttämättömien ja piilottamattomien sarakkeiden poistaminen ei ole tämän kautta mahdollista
- Käytä hyödyksi laskureita ja laskuriryhmiä (Calculation Group). Laskuriryhmien avulla voi toteuttaa järkevästi esim. aiemmin jokaiselle laskurille omat tiedot

vaatineet time-intelligence-funktiot. Samalla tekniikalla on mahdollista toteuttaa valintalaskureita, joita voidaan käyttää esimerkiksi summien kumulatiiviseen vertailuun. Nämä ovat mahdollista vain Tabular Editorin kautta

- Kerää teknistä velkoja aiheuttavat asiat ylös tietomalli- ja ratkaisukohtaisesti aktiivisesti kehittämisen aikana
- Kysy apua ja neuvoa muilta ihmisiltä. Käy läpi toteuttamiasi ratkaisujasi muiden kanssa.

Uusien tietomalleihin liittyvien käytäntöjen kehittämistä on mahdollista jatkaa miltei loputtomiin. Olennaisessa osassa on pohjimmiltaan samojen asioiden huomioiminen kuten 5.1. kappaleessa on mainittu. Tämän lisäksi aiheesta löytyy lisää liitteestä 2., sekä kappaleesta 3.6. ”mallintamisen parhaat käytännöt”. Internetistä löytyy useampia listauksia englanninkielisin hakusanoin, mikäli mallintamiseen liittyviä yleisimpiä virheitä tai parhaita käytäntöjä halutaan selvittää. Esimerkkejä työhön käytetyistä hakusanoista ja tietolähteistä löytyy kappaleesta 1.3.

5.4. Apuvälineiden käyttäminen

Apuvälineiden käyttämistä Power BI - ja Tabular-mallien kehittämisessä voidaan pitää välttämättömänä. Apuvälineiden käyttämisen avulla saadaan aikaan hyötyjä kehittämisen nopeuden suhteen, sekä avattua uusia ominaisuuksia Power BI -maailmassa. Tietty Power BI:ssä mukana olevat ominaisuudet voi saada käyttöön vain apuvälineiden avulla. Power BI:n käyttäjistö on aktiivinen BI-ammattilaisten ja kehittäjien yhteisö jotka luovat ilmaisia työkaluja kehittämistä varten. Ilmaiset apuvälineet parantavat ja laajentavat mallinnus-, integrointi, ja raportointiominaisuuksia (Microsoft, 2021c). Apuvälineiden käyttäminen helpottaa kehitystyötä, sekä siirtää tekemistä aikaa vievistä vähäpätöisistä tehtävistä varsinaiseen mallinnukseen ja itse liiketoiminnallisiin kysymyksiin.

Käyttämällä apuvälineitä mahdollistetaan parempi ja nopeampi kehittäminen, sekä paremmat lopputulokset ja tehokkaampi toiminta. Apuvälineiden käyttäminen vaativammassa kehittämisessä on Microsoftin valitsema linja, jonka mukaan se auttaa heitä keskittymään omiin kehitysprioriteetteihinsa paremmin. Microsoftin tavoitteena on pitkällä aikavälillä tarjota edistyneempiä kehitystyökaluja niin Power BI:lle kuin Analysis Services -palveluillekin,. Samalla kuitenkin lyhyen ajan prioriteettina on laajentaa BI-kehittäjien apuvälineiden

saatavuutta ammattimaisille BI-kehittäjille (Wade, 2021.). Ottaessa huomioon Microsoftin linjauksen voidaan ajatella, että apuvälineiden käyttäminen kehittämisessä tulee olemaan tulevaisuudessa entistä suuremmassa asemassa.

Tärkeimpinä apuvälineinä Power BI ja Analysis Services kehittämisessä pidetään Tabular Editoria ja DAX Studiota. Tämä koskee tuotteen menneisyyttä, nykyaikaa ja tulevaisuutta. Tabular Editoria pidetään ainoana ja välttämättömänä työvälineenä, jolla pääsee käsiksi organisaatiotason vaatimusten mukaisten tietomallien ominaisuuksiin. Organisaatiotason tabular-pohjaisten tietomallien kehittämisen suositellaan tapahtuvan Tabular Editorin avulla. Samalla DAX Studion käyttäminen tietomallien optimointiin ja DAX-koodin muokkaamiseen on suositeltu toimenpide. (Russo, 2021b.) Hyviä työn aikana esiin tulleita syitä apuvälineiden käyttöön löytyy seuraavasta listasta:

- Apuvälineet parantavat kehittämisen laatua
- Apuvälineitä on saatavilla ilmaiseksi
- Apuvälineet ovat välttämättömiä tiettyjen ominaisuuksien käyttöönottamiseen kannalta
- Vähentää vähäpätöisiin töihin menevää aikaa, esimerkiksi laskureiden siirtämisiin faktatauluista omiin kategorioihin. Tällä tavalla saadaan selkeytettyä nopeasti tietomallia samalla mahdollistaen aiemmin pidemmän aikaa vieneiden muutosten nopeammat muutokset
- Muutokset voidaan tehdä offline-tilassa, jolloin kaikki TOM-malliin tehdyt muutokset voidaan viedä yksittäisenä vientinä tietomalliin, ilman, että jokainen tehty muutos vaati tietomallin prosessointia
- Microsoft panostaa apuvälineiden kehitykseen eikä niiden tuki ole poistumassa
- Mahdollistaa tietomallin tarkemman tarkistelun
- Mahdollistaa mm. kieliversioiden tekemisen tietomalleille, jolloin monikieliset organisaatiot saavat samat tietomallit eri kielillä käyttöön
- Best Practice Analyzer mahdollistaa parhaiden käytäntöjen huomioon ottamisen silloin kun ne eivät ole ulkomuistissa

- Helpottaa tietomallien dokumentointia ja jakamista. VertiPaq Analyzerin avulla saa tietomallin dokumentointiin tarvittavia tietoja ulos.

Listaus itsessään ei pidä sisällään kaikkia hyötyjä, ja niitä on olemassa huomattavasti enemmän. Hyödyt apuvälineiden käyttöön selkenevät kehittäjälle nopeasti, kun lähdetään käyttämään ilmaisia ammattilaisten suosittelemia apuvälineitä. Ottaessa Tabular Editorin ja DAX Studion mukaan tietomallien kehitykseen, on hyvin vaikeaa nähdä kehittäjänä palaavansa vanhoihin toimintatapoihin, joissa apuvälineitä ei käytetä hyödyksi.

Tabular Editoria on järkevää käyttää hyödyksi aina kehittämisen aikana, aivan kuten DAX Studioita on järkevä käyttää tietomallin optimoinnin ja arvioinnin aikana. Varsinaisia hyväksyttäviä selityksiä apuvälineiden käyttämättä jättämiselle raporttien ja tietomallien kehittämisessä on vaikea perustella. Molemmat ovat avoimen lähdekoodin ratkaisuja, joiden tietoturvallisuudesta pääsee nopeasti perille. Samalla kummatkin kappaleessa mainitut apuvälineet ovat ilmaisia käyttää. Apuvälineiden käyttämättä jättäminen tekee vääjäämättä kehittäjän työstä hankalampaa ja hitaampaa. Microsoft tukee apuvälineiden käyttöä valtavasti ja samalla tunnetut kehittäjät pitävät apuvälineiden käyttöä välttämättömänä. Samalla tulevaisuudessa Power BI:hin liitännäisten apuvälineiden kehitys tulee jatkumaan suurella varmuudella tulevaisuudessa mutta laajemmalla skaalalla ja suuremmalla määrällä ominaisuuksia. Samalla apuvälineiden käyttämättömyys heikentää kehittäjien omia mahdollisuuksia lisätä osaamistaan, sekä luo ratkaisuille tarpeetonta teknistä velkaa, joka olisi toisenlaisilla toimintatavoilla ollut vältettävissä.

5.5. Teknisen velan vähentämisen tukitoiminnot mallintamisessa

Teknisen velan hallinnan yhtenä suurimpana haasteena pidetään Yli-Huurmoon, Maglyaksen ja Smolanderin (2016, s.212) mukaan apuvälineiden käytön puutetta. Teknisen velan hallinnointi ja minimointi tehdään usein ihmistyönä, ilman, että käytettäisiin velkaa minimoivia apuvälineitä. Työn tarkoituksena on löytää hyviä apuvälineitä teknisen velan minimointiin ja estämiseen. Yli-Hurmo et. al (2016, s 211.) kertovat tutkimuksessaan, että teknisen velan estäminen voidaan nähdä yhtenä eniten vaikuttavana aktiviteettina teknisen velan hallinnan toiminnoista. Teknisen velan estämisen hyödyistä ja niiden reaali maailman implementoinnin helppoudesta huolimatta teknistä velkaa estäviä apuvälineitä ei välttämättä käytetä. Suurin ongelma teknisen velan estämiseen liittyvien toimintojen käytössä on niiden käyttäminen vain silloin tällöin, koska organisaatiot eivät välttämättä ehdi työajan puutteesta

johtuen vaatimaan toiminnassaan teknistä velkaa minimoivien toimenpiteiden käyttöä. (Yli-Hurmoo et al., 2016.)

BI-välineiden mallintamiseen liittyvissä ongelmissa voidaan pitää hyödyllisinä keinoina apuvälineiden käyttöönottoa, tarkistuslistoja, jatkuvien kehittämistä parantavien ja helpottavien toimintatapojen noudattamista kiireestä riippumatta, mallintamiskäytäntöjen opettelemista ja ymmärtämistä, mahdollisten teknisten velkoja aiheuttavien asioiden kirjaamista ylös ja niiden käsittelemistä, tiedon jakamista, vertaisarviointia, sekä alusta saakka hyvien toimintatapojen mukaan toimimista.

Hyödyntäessä Tabular Editorin Best Practice Analyzeriä aiemmin useasti mainittujen Microsoftin parhaiden käytäntöjen kanssa saadaan aktiivisesti tehtyä tarkistuksia siitä, miten mallinnuksessa on suoriuduttu. Tällöin saadaan vähennettyä teknisen velan aiheuttamia ongelmia alusta saakka, sekä parannettua kehittäjien tietotaitoa. Lyhyesti sanottuna voidaan todeta, että alusta saakka hyviksi todettujen tapojen mukaisesti toimiminen on kannattavaa. Samalla olisi järkevää varata aikaa myös vanhojen tietomallien kehittämiseen ja optimointiin sekä selkeyttämiseen, mikäli niiden kehitystiekartalla nähdään tulevaisuudessa tarpeita. Olemassa olevien hyvin toimivien raporttien optimointi ja jälkikäteen arviointi sekä kehittäminen ei ole kuitenkaan kaikissa tilanteissa tarpeellista. Jos raportin tietomalli on hyvä, ja käytötarkoitus on selkeä eikä jatkokehitystarpeita ole tiedossa lähivuosien aikana, voidaan helposti pitää ymmärrettävänä käyttää aika tärkeämpiin asioihin.

Kehittämisen jälkeen tapahtuvaan vertaisarviointiin tulee varata aikaa, jolloin olisi hyvä käydä lävitse teknistä velkaa aiheuttaneet ylös kirjatut asiat. Vertaisarviointi olisi viisaampaa hoitaa ihmisten välisissä palaverissa, koska silloin on helpointa välttyä kirjoitetun tekstin aiheuttamilta väärinymmärryksiltä. Samalla vertaisarvioinnissa tulisi kirjata ylös sovitut toimenpiteet ja muut huomattavat asiat. Ylös kirjatuilla toimenpiteillä saadaan dokumentoitua teknistä velkaa aiheuttaneita asioita, jolloin vertaisarvioinnin ja jatkokehityksen myynti sidoryhmille helpottuu, eikä se vaikuta vain ajanhukalta, joka vie aikaa muulta tuottavalta työltä.

Aiemmin kappaleessa 4.4. mainitun teorian mukaisesti kehittäjät pitävät vertaisarviointien parhaimpana puolina koodin oikeellisuuden parantamista, luettavuuden parantamista, monen silmäparin tarkisteluvarmistamista ratkaisulle, paremman ylläpidettävyyden, paremman suunnittelun, osaamisen jakamisen, reliabiliteetin parantamisen, paremman koodin muotoilun sekä parantuneen dokumentoinnin laadun. Näiden syiden avulla voidaan

perustella vertaisarvioinnin tärkeyden järkevyys. Vertaisarviointia ja muita tukitoimia varten olisi hyödyllistä virallistaa prosessit organisaation sisällä. Vain seuratulla prosessinomaisella toiminnalla, jota dokumentoidaan, saadaan vahvistus siihen, että järkeviä toimintatapoja noudatetaan.

Vertaisarvioinnissa tärkeää on se, että siihen riittää aikaa, sitä ei jätetä väliin, sitä tapahtuu ja apuvälineitä käytetään hyödyksi. Suuremman määrän kehittäjiä omaavissa organisaatioissa voidaan järjestää esimerkiksi yritysten sisäisesti kuukausittainen tai kerran kahteen viikkoon tuleva aikataulutettu keskustelu, jossa käydään läpi yhdestä mallista tehtyä vertaisarviointia. Järkevänä myös pitää kehittäjätiimin kanssa yhdessä läpi käytäviä toimintatapojen arviointia.

6. Yhteenveto ja johtopäätökset

Kuudennessa luvussa kerrotaan työhön liittyvä yhteenveto, sekä käydään tutkimuskysymyksiin saadut vastaukset läpi. Johtopäätöksissä käydään läpi, mitä diplomityöstä on opittu, ja miksi työtä on syytä pitää tärkeänä. Kappaleessa kerrotaan hyötyjä taloudellisesta, tietomallinukseen liittyvistä ja kehittämiseen liittyvistä näkökulmista.

6.1. Yhteenveto

Tutkimuksessa lähdettiin selvittämään mitä teknologioita ja parhaita käytäntöjä löytyy Power BI - ja Tabular-malleihin. Nämä voidaan jakaa toimenpiteellisiin käytäntöihin, teoriaan ja teknologioihin. Toimenpiteelliset käytännöt pitävät sisällään määrittelyt, niihin liittyviä ohjeet sekä yleisiä toimintatapoja. Parhaita käytäntöjä, jotka liittyvät valittujen teknologioiden käyttämiseen voidaan kategorisoida esimerkiksi aiemmin mainitun mallintamisen parhaat käytännöt 3.6. kappaleen mukaan DAX koodiin, ongelmien välttämiseen, tekstin muotoiluun, mallin ylläpidettävyyteen, nimeämiskäytäntöihin ja suorituskäytännöihin vaikuttaviin asioihin. Näiden asioiden ymmärtämiseen ja toteuttamiseen auttaa teknologioiden taustalla olevan teorian ymmärtäminen, johon taas liittyy tarkemmin dimensionaalisen mallinnuksen käytännöt, taustalla oleva VertiPaq-moottori ja sen toiminta, sekä yleisten mallikohtaisten kuten useamman taulun käyttöön liittyvien asioiden oikeanlaatuinen selvittäminen. Näitä kyseisiä teorioita voidaan käydä passiivisesti läpi kehityksen aikana käyttämällä apuvälineiden ja vapaasti jaossa olevien parhaiden käytäntöjen GitHubista datasettiä (Kovalsky, 2021a). Kyseisen datasetin luettavaan muotoon muokattu taulukko löytyy liitteestä 2.

Diplomityön toinen tutkimuskysymys oli, ” Miksi ja miten parhaita käytäntöjä pitäisi implementoida olemassa oleviin ja tuleviin tietomalleihin?”. Uusien ja vanhojen tietomallien kehittämisessä tulisi käyttää apuvälineitä, kuten Tabular Editoria ja DAX Studiota sekä sen sisällä olevaa VertiPaq Analyzeria. Tärkeä osa parhaiden käytäntöjen noudattamista on kuitenkin huolellisesti ja hyvin tehdyt määrittelyt, sekä oikeat yrityksen toimintatavat. Toimintatapojen osalta olisi tärkeää virallistaa organisaatioille sisäiset pelisäännöt sen suhteen, kuinka teknologioiden kanssa toimitaan. Vanhojen mallien kehittämisessä tietomallien parhaiden käytäntöjen implementointi onnistuu usein parhaiten käymällä läpi mallit niin

Tabular Editorin Best Practice Analyzerin kuin VertiPaq Analyzerinkin avulla. Tabular Editorilla huomataan helposti mallissa tehty epäoptimaaliset ratkaisut, ja voidaan nopeasti korjata kaikista suurimmat performanssia aiheuttavat ongelmat. Vanhemmista tietomalleista löytyy usein paljon kardinaliteettia nostavia kenttiä. Suuri kardinaliteetti aiheuttaa tietomalleille suorituskyvyn heikentymistä ja tarpeetonta tietomallin koon suurentumista. Tietomallin koko ja suorituskky ovat usein nopeilla ja helpoilla toimenpiteillä optimoitavissa parempaan, ja esimerkiksi liian tarkalla tasolla olevat desimaaliluvut kuten 0.9313123 voidaan pyöristää pienempään kahden desimaalin omaavaan 0.93 muotoon, jolloin aikaisemmat tarkemmat 0.93 alkuiset luvut saadaan sanakirjasto enkoodauksen avulla pakattua pienempään tilaan. Tällöin tallennettavien ja haettavien yksittäisten rivien määrä ja tietomallin koko pienenevät, ja sillä voidaan arkkitehtuurillisista ratkaisuista riippuen saada aikaan rahallisia säästöjä, kun kapasiteettia tarvitaan vähemmän. Uusissa tietomalleissa nämä mainitut asiat voidaan hoitaa alusta alkaen samoilla parhaiden käytäntöjen säännöillä (liite 2) kuntoon, jolloin suorituskvyn heikennyksiä aiheuttaviin teknisiin kohtiin saadaan reagoitua jo kehityksen aikana. Uusia tietomalleja julkaistaessa kannattaa luoda organisaation sisäiset pelisäännöt, joiden noudattaminen vaatii tuotantoon julkaiseminen. Ratkaisuna voi olla esimerkiksi tarkistuslista ja Best Practice Analyzerin läpikäynti työn loppuvaiheessa yhdessä toisten kehittäjien kanssa. Best Practice Analyzeriä voidaan käyttää avuksi vertaisarviointia tehdessä. Uusien mallien kehittämisessä erityisen tärkeässä osassa on määrittelyjen tekeminen kunnonlla. Huonot määrittelyt reflektoituvat usein tietomallien suorituskvyn heikkouteen, sekä luovat tarpeettomia ongelmia jatkokehitystä ajatellen, jos esimerkiksi skaalautuvuutta ei ole ajateltu tarpeeksi, tai pahimmissa tapauksissa lainkaan.

Tietomallien optimointia ja parhaiden käytäntöjen mukaan toimimista kannattaa toteuttaa sen takia, että se mahdollistaa kehittäjien paremman oppimisen sekä aktiivisen palautteen saamisen. Tietomallin koon laajentaminen ja performanssiin liittyvien asioiden pienentäminen taas aiheuttaa mallin paremman ja nopeamman toimisen, joka voi johtaa pienempiin kustannuksiin riippuen käytetyistä lisenssinneista. Power BI Embedded -lisenssiä käyttäessä suurimman A6-kapasiteetin käytön välttäminen käyttämällä pienempää kapasiteettia A5 toisi kuukausittaiset 9 561 € säästöt. Säästön voi todeta liiteestä 3 löytyvän hinnaston avulla. Vuodessa tämä toisi jo 114 734 € säästöt, jotka jo itsessään kertovat sen, että tietomalleja on kannattavaa optimoida pelkästään taloudellisen näkökulman kannalta. Samalla parhaita käytäntöjä hyödyntämällä saadaan ratkaistua DAX koodiin, ongelmien välttämiseen, tekstin muotoiluun, mallin ylläpidettävyyteen ja nimeämiskäytäntöihin liittyviä huomattuja

ongelmakohtia, jotka taas vaikuttavat tietomallien mahdolliseen tulevan kehittämisen helpottamiseen, sekä tietomallin ymmärtämisen parantamiseen. Tällöin noudattamalla parhaita käytäntöjä saadaan teknistä velkaa minimoitua helposti. Samalla parannetaan myös toimintatapoja ja pienennetään varsinaiseen kehitystyöhön menevää aikaa.

Tietomallien kehittämistä varten vaaditaan myös tukitoiminnot, joiden avulla parhaita käytäntöjä voidaan implementoida. Näiden toimenpiteiden implementoinnilla voidaan pyrkiä vähentämään teknistä velkaa. Yksi työn tutkimuskysymyksistä olikin selvittää, että minkälaiset tukitoiminnot avustavat parhaiden käytäntöjen implementointia, noudattamista ja teknisen velan vähentämistä. Avustavia aiemmin työssä 4.4. kappaleessa mainittuja ohjelmiston katselmointiin ja parhaiden käytäntöjen implementointiin liittyviä tukitoimintoja ovat tarkistuslistat, apuvälineiden käyttö, prosessien virallistaminen, työntekijöiden ja vertaisarviointiin käytettävän työajan lisääminen, kannustimien mukaan ottaminen, sekä nopeamman vertaisarvioinnin syklin mahdollistaminen. Työn tutkimuskysymyksistä saadut vastaukset kertovatkin kattavasti ratkaisuja näihin ongelmiin. Erityisen tärkeänä osana tätä kokonaisuutta tulee nostaa esiin vertaisarviointi. Vertaisarvioinnin avulla voidaan varmistaa, että itsenäisesti tapahtuneessa kehittämisessä on noudatettu parhaita käytäntöjä, sekä teknistä velkaa aiheuttavia ongelmia on minimoitu. Vertaisarvioinnin koetaan parantavan koodin laatua huomattavasti. Kehittäjiin kohdistetussa tutkimuksessa 77 kehittäjää 84 kehittäjästä kertoi-kin kokevansa sen parantavan koodin laatua huomattavasti (Nasir & Carver, 2021, s.17–18). Vertaisarvioinnin koetaan parantavan koodin oikeellisuutta, luovan paremman luettavuuden, mahdollistavan useamman silmäparin tarkastelun, parantavan ylläpidettävyyttä, suunnittelua ja osaamisen jakamista.

Työssä saatiin luotua hyvin ratkaisuja Power BI - ja Tabular-mallien, eli VertiPac-pohjaisten tietomallien optimointiin sekä parantamiseen tietomallin kuin toimintatapojen kautta. Käytännön osuus kattaa hyvin mallintamisen kannalta tärkeät teknologiat ja parhaimmat käytännöt, sekä antaa ohjeita niiden implementointiin ja kertoo minkä takia toimintatapoja kannattaisi muuttaa. Työssä keskityttiin teknisen velan vähentämisen tukitoimintoihin, jotka voivat auttaa organisaatioita parantamaan työnsä laatua kokonaisvaltaisesti BI-projektien ulkopuolella. Työosuuden tulokset voidaan jakaa kolmeen eri kategoriaan. Kategorioista ensimmäinen on määrittelyt, toinen jatkuvan kehittämisen toimintatavat sekä tukitoiminnot ja kolmas tiedon mallintamiseen liittyvät huomiot.

Määrittelyihin liittyvät tehtävät ovat tärkeää hoitaa kunnolla, mikäli ollaan toteuttamassa uusia ratkaisuja ja määrittelyvaihe on tekemättä. On tärkeää selvittää vaadittavat käyttötarkoitukset sekä mahdollisuudet teknisiä ratkaisuja varten. Usein tiedolla johtamisen ratkaisussa voidaan tarjota raportin ja tietomallin tilanneelle taholle huomattavasti pyydettyä enemmän, kun osataan esittää aiheeseen liittyviä hyvät kysymykset. Käyttötarkoitusten selvittäminen merkitsee tietomallien kehittämisessä paljon, sillä se antaa pohjapiirustuksen ja luo alustavan suunnitelman, jonka avulla voidaan välttää teknistä velkaa ja tulevia ongelmia koko kehittämisen ajalle. Tästä syystä olisi järkevää selvittää kunnolla tulevien projektien raportti- ja tietovaatimukset, elleivät ne ole jo selvillä muiden dokumentoitujen ja liitännäisten kokonaisuuksien kautta. Raportti- ja tietovaatimusten rakentamisen pohjalla voidaan käyttää avuksi esimerkiksi tästä työstä löytyviä taulukkoja 5. ja 6. Kehittämisen alkaessa on pidetty järkevänä palata vielä myöhemmin määrittelydokumentteihin ja käsitellä niitä uudestaan tuotekokonaisuuteen liittyvien sidosryhmien kanssa. Analytiikkaratkaisuja kehittäessä nälkä usein kasvaa syödessä ja uusia ideoita sekä tarpeita löytyy projektin edetessä.

Jatkuvan kehittämisen toimintatavat ja tukitoiminnot liittyvät tekemiseen, jossa puhutaan tietomallien aktiivisesta päivittäisestä kehittämisestä sekä siihen liittyvistä tukitoiminnoista jotka auttavat helpottamaan kehittämistä. Ideana on ollut kerätä ohjeita ja neuvoja, jotka helpottavat teknisen velan minimointia ja parhaiden käytäntöjen implementointia jatkuvasti samalla ollen riippumaton siitä, ollaanko projektissa alku- vai loppuvaiheessa. Työn aikana hyödyllisiksi katsotut toimintatavat sekä tukitoiminnot löytyvät seuraavasta listasta:

- Apuvälineet auttavat kehittämisessä sekä teknologisen taustan ymmärtämisen kehittämisessä, opettele käyttämään apuvälineitä sekä käytä niitä
- Kirjaa kehittäessä ylös teknistä velkaa mahdollisesti muodostavat asiat ylös, sekä käsittele näitä virheitä myöhemmin projektien ja ratkaisujen valmistuessa
- Käy tietomallin ja raportin ratkaisuja läpi muiden kehittäjien kanssa, samat aikaansaadut asiat voidaan useasti tehdä järkevimmillä tavoilla. Järkevämmin tekeminen voi nopeuttaa niin kehittämistä kuin tietomalliakin
- Teknologisen taustan ymmärtäminen ja osaaminen on kehittäjille ja teknisestä arkkitehtuurista vastaaville tärkeää. Ymmärrettäessä taustalla toimivan teknologian, kyetään ymmärtämään miksi parhaiden käytäntöjen mukaan tulisi toimia, sekä kyetään havainnoimaan tehtyjen ja tekemättömien toimien vaikutuksia jo etukäteen

- Projektien tullessa valmiiksi pitääkää vertaisarviointeja muiden Power BI -ekosysteemissä toimivien kanssa ja käykää lävitse ratkaisuja. Vaikka lopullisia päätöksiä ratkaisujen muokkaamiseen ei tehtäisikään, on hyvä käydä läpi tietyn tyylliset ratkaisut ja miksi tämän-kaltaisiin asioihin on päädytty. Samalla voidaan selvittää miten kehitysvaiheessa olisi voitu toimia toisella tavalla. Sitä kautta voi selvittää uusia tärkeitä tietoja organisaation sisällä. Jos syyksi heikkotasoiisiin ratkaisuihin on jatkuvasti esimerkiksi osaamisen ja teknisen ymmärryksen tai ajan puute, ja se saadaan kirjattua ylös, niin sillä mahdollistetaan kyseisten asioiden huomiointi ja korjaaminen
- Vertaisarviointiin on tärkeää varata aikaa, sekä virallistaa niiden prosessit organisaatiossa, muuten ne jäävät todennäköisesti tekemättä
- Pitäkää esittelyjä tekemistänne ratkaisuihin. Tiedon jakaminen auttaa aina. Esittelyt ja tiedonjakaminen auttaa koko organisaatiota ja varsinkin nuorempia kehittäjiä ymmärtämään teknisiä ratkaisuja ja näkemään miten ongelmia korjataan.
- Kerää teknistä velkaa aiheuttavat asiat ylös. Ylös kerätyt teknistä velkaa aiheuttavat ongelmat voidaan lisätä tehtävälistalle ylös käsiteltäviksi ja priorisoida tarpeen mukaan. Teknistä velkaa aiheuttavat ongelmat johtuvat pääsääntöisesti niiden ylös merkitsemättömyydestä
- Keräämällä teknistä velkaa aiheuttavia asioita ylös voidaan myydä helpommin teknologisten ratkaisujen enemmän aikaa vievät ratkaisut sidosryhmille, kun riskit on arvioitu ja huomioitu

Datan mallintamisessa kannattaa ottaa huomioon, että kunnolla hoidettu määrittely ja hyödylliset aktiiviset jatkuvan kehittämisen toimintatavat parantavat tiedon mallintamista. Tiedon mallintamiseen kannattaa käyttää apuvälineitä, joiden todennettu käyttämisen hyöty on kiistaton. Apuvälineet mahdollistavat ominaisuuksien mukaan ottamista sekä asioiden huomioimista, jotka eivät Microsoftin tarjoamilla tuotteilla olisi mahdollista. Tabular Editorin Best Practice Analyzerilla saadaan korjattua enemmän parhaiden käytäntöjen vastaisia toimia, kun kehittäminen on vielä aluillaan. Tarkemmat tiedot parhaista käytännöistä ja niihin liittyvistä asioista löytyvät kappaleen 5.3. listauksesta sekä Liitteestä 2. VertiPaq Analyzerin avulla huomautetut tietomallin datan epäpuhtaudet ja kokoon vaikuttavat asiat saadaan vielä korjattua erikseen. VertiPaq Analyzerilla voi tallentaa tietomallin metatiedot VPAX-

tiedostoon ja sen voi lähettää työkaverille arvioitavaksi ja tarkistettavaksi. Tämä ei pidä sisällään varsinaista dataa, jolloin sen käyttö on turvallista ulkopuolisille arviointia tekeville tahoille.

Kokonaisuudessaan voidaan katsoa määrittelyn, jatkuvan kehittämisen toimintatapojen sekä tukitoimintojen ja tiedon mallintamiseen liittyvien huomioiden sitoutuvan yhteen kokonaisuudeksi, jossa yhden heikompi laatu vaikuttaa muihinkin asioihin. Jos tekninen osaaminen on korkealla tasolla, mutta haluttavan lopputuotteen määrittely on heikko, on tällöin hyvin vaikeaa saada aikaan hyviä tuloksia. Jos määrittely on hyvä mutta helpottavia teknisiä apuvälineitä ei käytetä, vie kehittäminen enemmän aikaa eikä tällöin epäkohtiin ehditä puuttumaan niin paljoa projektin edetessä. Lyhykäisyydessään voidaan todeta, että kaikkiin näihin kokonaisuuksiin tulee kiinnittää huomiota yhdessä vaikutusten kannalta ja erikseen asiata-solla.

6.2. Johtopäätökset

Toimintatapojen aktiiviseen kehittämiseen ja muuttamiseen tarvitaan sidosryhmien tukea sekä johdonmukaista päätöksentekoa. Työssä vastattiin mielestäni hyvin siihen, minkälaisia asioita pitäisi Power BI - ja Tabular-mallinnusta tehdessä tietää. Työssä esitettiin useita toimintatapojen ja kehittämisen keinoja, konkreettisia toimenpiteitä, sekä perusteluita, joiden avulla niitä kyetään myymään sidosryhmille ja asiakkaille. Tutkimuksen kautta löydettiin sopivia apuvälineitä kehittämistä varten, joiden hyödyt näytettiin kiistattomiksi. Kiistatonta oli myös se, että Microsoft tukee vahvasti yhteisöään heidän apuvälineiden kehityksen työssä sen ollessa osa heidän strategiaansa. Samalla kyettiin myös toteamaan, että apuvälineiden käyttäminen helpottaa ja parantaa kehitystyötä, sekä siirtää tekemistä aikaa vievistä vähäpätöisistä tehtävistä varsinaiseen mallinnukseen ja raporttiominaisuuksien kehittämiseen. Käyttämällä työn tuloksia hyödyksi saadaan mahdollistettua organisaatioiden teknisen velan vähentyminen ja osaamisen tason parantuminen. Näin ollen työn voidaan olevan aihe-alueellaan oleellinen kehitysprojekti.

Tutkimuksen teoreettinen pohja vastaa mallintamiskäytäntöihin liittyviin kysymyksiin, sekä kasaa koostetusti yhteen VertiPaaS-moottoria hyödyntävien teknologioiden tärkeimmät osat, sekä niiden mallintamiseen liittyvät käytännöt. Kokonaisuutena vastaavia suomenkielisiä yhteen kasattuja teoria- ja käytäntökokonaisuuksia ei ole helposti löydettävissä. Mallintamiseen ja parhaisiin käytäntöihin liittyvää materiaalia ja ratkaisuja parhaiden käytäntöjen

toteuttamiseen on vähän saatavilla kirjallisessa muodossa. Yksi syy paljon käytettyyn internet-materiaaliin on sen ajankohtaisuus ja virallisuus.

Tutkimuksessa pyrittiin keskittymään teknologioihin ja niistä löytyviin hyötyihin, kuin varsinaiseen apuvälineiden käyttämiseen ja sen kirjaamiseen ylös. Apuvälineiden käyttämiseen löytyy valtava määrä muiden yhteen keräämiä materiaaleja internetistä. Nämä eivät olleet olennainen osa tutkimusta. Tämän työn tärkeimmät tulokset ovat tarkasti valikoitu teoriaosuus, sekä oikein mallintamisen ja toimimisen hyödyt Power BI - ja Tabular-pohjaisiin tietomalleihin. Työ tarjoaa myös listauksen helpoista toimenpiteistä, joilla saadaan parannettua omaa toimintaa.

Lähteet

Branscombe, M (2021). 10 Power BI mistakes to avoid. (2021). <https://www.cio.com/article/189225/10-power-bi-mistakes-to-avoid.html>. (luettu 24.1.2022).

Carullo, G (2020). Implementing Effective Code Reviews. Berkeley, CA: Apress L. P. [https://ebookcentral.proquest.com/lib/\[SITE_ID\]/detail.action?docID=6336346](https://ebookcentral.proquest.com/lib/[SITE_ID]/detail.action?docID=6336346).

Duncan, O, Sharkey K. & Kinsman M. (2021). DAX function reference - DAX. (2021). <https://docs.microsoft.com/en-us/dax/dax-function-reference>. (luettu 2021).

Eisty, N & Jeffrey, C. (2021). Developers perception of peer code review in research software development. New York: Springer US, 27(1). <https://link.springer.com/article/10.1007/s10664-021-10053-x>. DOI: 10.1007/s10664-021-10053-x.

Enho, H. (2021). Power BI - kaikki mitä sinun tulee tietää aloittaaksesi. (2021). <https://su-lava.com/liiketoiminnan-digitalisointi-tiedolla-johtaminen/power-bi-kaikki-mita-sinun-tulee-tietaa-aloittaaksesi/>. (luettu 16.11.2021).

Ferrari, A & Russo, M (2017). Analyzing data with Microsoft Power BI and Power Pivot for Excel. Microsoft Press. <http://cds.cern.ch/record/2267681>.

Gartner (2021). Gartner Forecasts Worldwide IT Spending to Exceed \$4 Trillion in 2022. (2021). <https://www.gartner.com/en/newsroom/press-releases/2021-10-20-gartner-forecasts-worldwide-it-spending-to-exceed-4-trillion-in-2022>. (luettu 2022).

Hart, M (2021). Mikä Power BI -sovellus on? - Power BI. (2021). <https://docs.microsoft.com/fi-fi/power-bi/consumer/end-user-apps>. (luettu 3.12.2021).

Inbar, P (2021). Sisältösi tukeminen - Power BI. (2021). <https://docs.microsoft.com/fi-fi/power-bi/collaborate-share/service-endorse-content>. (luettu 27.12.2021).

Iseminger, D (2021). Mikä on Power BI Desktop? - Power BI. (2021). <https://docs.microsoft.com/fi-fi/power-bi/fundamentals/desktop-what-is-desktop>. (luettu 25.11.2021).

Jaakola, T. & Sarja J. (2006). Tietokantoihin liittyviä käsitteitä . (2006). <https://verkkopedagogi.net/vanhat/fi/sisalto/materiaalit/access2003/luku06ce4a.html?C:D=419705&sel-res=419705>. (luettu 2021).

Kollanus, S. & Koskinen, J. (2009). Survey of Software Inspection Research. 3(1), 15–34. DOI: 10.2174/1874107X00903010015.

Kovalsky, M (2021a). Best Practice Rules. (2021). <https://github.com/microsoft/Analysis-Services/tree/master/BestPracticeRules>. (luettu 2022).

(2021b). Best practice rules to improve your model's performance. (2021). <https://powerbi.microsoft.com/en-us/blog/best-practice-rules-to-improve-your-models-performance/>. (luettu 10.12.2021). Llopis, M. (2021). Mikä on Power Query? (2021). <https://docs.microsoft.com/fi-fi/power-query/power-query-what-is-power-query>. (luettu 27.12.2021).

Mabee, D. (2020). Relationships in Analysis Services tabular models. (2020). <https://docs.microsoft.com/en-us/analysis-services/tabular-models/relationships-ssas-tabular>. (luettu 25.11.2021).

ManpowerGroup (2021). ManpowerGroup Employment Outlook Survey: Global;2021 SRI B5275-5.48908. <https://statistical.proquest.com/statisticalinsight/result/pqpresultpage.previewtitle?docType=PQSI&titleUri=/content/2021/B5275-5.48908.xml>.

Microsoft (2021a). DAX-syntaksi - DAX. (2021). <https://docs.microsoft.com/fi-fi/dax/dax-syntax-reference>. (luettu 2021).

(2021b). Power Query käyttöliittymä. (2021). <https://docs.microsoft.com/fi-fi/power-query/power-query-ui>. (luettu 27.12.2021).

(2021c). Ulkoiset työkalut Power BI Desktop - Power BI. (2021). <https://docs.microsoft.com/fi-fi/power-bi/transform-model/desktop-external-tools>. (luettu 28.12.2021).

(2022a). Center of Excellencen luominen - Power BI. (2022). <https://docs.microsoft.com/fi-fi/power-bi/guidance/center-of-excellence-establish>. (luettu 24.1.2022).

(2022b). Mikä Power BI -palvelu on? (2022). <https://docs.microsoft.com/fi-fi/power-bi/fundamentals/power-bi-service-overview>. (luettu 2022).

(2022c). Vaatimusten kerääminen siirryttäessä Power BI:hin. (2022). <https://docs.microsoft.com/fi-fi/power-bi/guidance/powerbi-migration-requirements>. (luettu 21.1.2022). Otykier, D (2021). Tabular Editor. (2021). <https://docs.tabulareditor.com/>. (luettu 2021).

Owen, D., Coulter D. & Petersen T. (2021). Tabular Object Model (TOM). (2021). <https://docs.microsoft.com/en-us/analysis-services/tom/introduction-to-the-tabular-object-model-tom-in-analysis-services-ammo>. (luettu 11.2.2022).

Russo, Marco (2018). Power BI is a model-based tool - SQLBI. (2018). <https://www.sqlbi.com/articles/power-bi-is-a-model-based-tool/>. (luettu 16.11.2021).

(2021a). Data Model Size with VertiPaq Analyzer - SQLBI. (2021). <https://www.sqlbi.com/articles/data-model-size-with-vertipaq-analyzer/>. (luettu 13.12.2021).

(2021b). Development tools for Tabular models in 2021 - SQLBI. (2021). <https://www.sqlbi.com/articles/development-tools-for-tabular-models-in-2021/>. (luettu 25.1.2022).

Russo, M & Ferrari, A. (2015). The Definitive Guide to DAX: Business intelligence with Microsoft Excel, SQL Server Analysis Services, and Power BI. Microsoft Press. <https://learning.oreilly.com/library/view/~9780735698383/?ar>.

(2021). Power BI – Star schema or single table - SQLBI. (2021). <https://www.sqlbi.com/articles/power-bi-star-schema-or-single-table/>. (luettu 2.12.2021).

von See, A. (2021). Total data volume worldwide 2010-2025. (2021). <https://www.statista.com/statistics/871513/worldwide-data-created/>. (luettu 6.1.2022).

SQLBI (2021). VertiPaq Analyzer - SQLBI. (2021). <https://www.sqlbi.com/tools/vertipaq-analyzer/>. (luettu 28.12.2021).

Ulagaratchagan, A. (2021). Microsoft named a Leader in the 2021 Gartner Magic Quadrant for Analytics and BI Platforms. (2021). <https://powerbi.microsoft.com/en-us/blog/microsoft-named-a-leader-in-2021-gartner-magic-quadrant-for-analytics-and-bi-platforms/>. (luettu 16.11.2021).

Wade, C. (2021). Community and third-party tools for developing enterprise-level Power BI and Analysis Services models. (2021). <https://powerbi.microsoft.com/fi-fi/blog/community-tools-for-enterprise-powerbi-and-analysisservices/>. (luettu 2021).

Wilson, D. (2017). Tabular Modeling with SQL Server 2016 Analysis Services Cookbook. Birmingham, England: Packt Publishing. <http://unr-ra.scholarvox.com/book/88842654>.

Yli-Huumo, J., Maglyas A. & Smolander K. (2016). How do software development teams manage technical debt? – An empirical study. Elsevier Inc, , 195–218. <https://dx.doi.org/10.1016/j.jss.2016.05.018>. DOI: 10.1016/j.jss.2016.05.018.

Qlik a leader in the 2020 Gartner Magic Quadrant -. (2020). (2020). <https://www.climber.fi/qlik-a-leader-in-the-2020-gartner-magic-quadrant/>. (luettu 7.2.2022).

DAX Studio. (2021). (2021). <https://daxstudio.org/>. (luettu 28.12.2021).

DAX Studio - SQLBI. (2021). (2021). <https://www.sqlbi.com/tools/dax-studio/>. (luettu 28.12.2021)..

Liite 1. Azure Analytics Services hinnasto 2.12.2021

Instance	QPU's	Memory (GB)	Price ¹
S0	40	10	€528.112/month
S1	100	25	€1,323.539/month
S2	200	50	€2,647.078/month
S4	400	100	€5,287.635/month
S8	320	200	€6,767.651/month
S8 v2	640	200	€10,718.707/month
S9	640	400	€13,535.302/month
S9 v2	1280	400	€21,437.414/month

Liite 2. Parhaiden käytäntöjen tarkemmat kuvaukset avoimesta Microsoftin datasetistä

Kategoria	Nimi	Kuvaus	Va- ka- vuus s	Yhteenso- pivuus- taso
DAX Ex- pressions	[DAX Expressions] No two measures should have the same definition		2	1200
DAX Ex- pressions	[DAX Expressions] Avoid using the IFERROR function	Avoid using the IFERROR function as it may cause performance degradation. If you are concerned about a divide-by-zero error, use the DIVIDE function as it naturally resolves such errors as blank (or you can customize what should be shown in case of such an error). Reference: https://www.elegantbi.com/post/top10bestpractices	2	1200
DAX Ex- pressions	[DAX Expressions] Inactive relationships that are never activated	Inactive relationships are activated using the USERELATIONSHIP function. If an inactive relationship is not referenced in any measure via this function, the relationship will not be used. It should be determined whether the relationship is not necessary or to activate the relationship via this method. Reference: https://docs.microsoft.com/powerbi/guidance/relationships-active-inactive Reference: https://dax.guide/userrelationship/	2	1200
DAX Ex- pressions	[DAX Expressions] Filter measure values by columns, not tables	Instead of using this pattern FILTER('Table',[Measure]>Value) for the filter parameters of a CALCULATE or CALCULATETABLE function, use one of the options below (if possible). Filtering on a specific column will produce a smaller table for the engine to process, thereby enabling faster performance. Using the VALUES function or the ALL function depends on the desired measure result. Option 1: FILTER(VALUES('Table'[Column]),[Measure] > Value) Option 2:	2	1200

		<code>FILTER(ALL('Table'[Column]),[Measure] > Value)</code> Reference: https://docs.microsoft.com/power-bi/guidance/dax-avoid-avoid-filter-as-filter-argument		
DAX Expressions	[DAX Expressions] Filter column values with proper syntax	Instead of using this pattern <code>FILTER('Table','Table'[Column]="Value")</code> for the filter parameters of a <code>CALCULATE</code> or <code>CALCULATETABLE</code> function, use one of the options below. As far as whether to use the <code>KEEPFILTERS</code> function, see the second reference link below. Option 1: <code>KEEPFILTERS('Table'[Column]="Value")</code> Option 2: <code>'Table'[Column]="Value"</code> Reference: https://docs.microsoft.com/power-bi/guidance/dax-avoid-avoid-filter-as-filter-argument Reference: https://www.sqlbi.com/articles/using-keepfilters-in-dax/	2	1200
DAX Expressions	[DAX Expressions] Use the <code>TREATAS</code> function instead of <code>INTERSECT</code> for virtual relationships	The <code>TREATAS</code> function is more efficient and provides better performance than the <code>INTERSECT</code> function when used in virtual relationships. Reference: https://www.sqlbi.com/articles/propagate-filters-using-treatas-in-dax/	2	1400
DAX Expressions	[DAX Expressions] Measures should not be direct references of other measures	This rule identifies measures which are simply a reference to another measure. As an example, consider a model with two measures: <code>[MeasureA]</code> and <code>[MeasureB]</code>. This rule would be triggered for <code>MeasureB</code> if <code>MeasureB</code>'s DAX was <code>MeasureB:=[MeasureA]</code>. Such duplicative measures should be removed.	2	1200
DAX Expressions	[DAX Expressions] Use the <code>DIVIDE</code> function for division	Use the <code>DIVIDE</code> function instead of using <code>"/"</code>. The <code>DIVIDE</code> function resolves divide-by-zero cases. As such, it is recommended to use to avoid errors.	2	1200

		Reference: https://docs.microsoft.com/en-us/power-bi/guidance/dax-divide-function-operator		
DAX Expressions	[DAX Expressions] Column references should be fully qualified	Using fully qualified column references makes it easier to distinguish between column and measure references, and also helps avoid certain errors. When referencing a column in DAX, first specify the table name, then specify the column name in square brackets. Reference: https://www.elegantbi.com/post/top10bestpractices	3	1200
DAX Expressions	[DAX Expressions] Measure references should be unqualified	Using unqualified measure references makes it easier to distinguish between column and measure references, and also helps avoid certain errors. When referencing a measure using DAX, do not specify the table name. Use only the measure name in square brackets. Reference: https://www.elegantbi.com/post/top10bestpractices	3	1200
Error Prevention	[Error Prevention] Expression-reliant objects must have an expression	Calculated columns, calculation items and measures must have an expression. Without an expression, these objects will not show any values.	3	1200
Error Prevention	[Error Prevention] Data columns must have a source column	Data columns must have a source column. A data column without a source column will cause an error when processing the model.	3	1200
Error Prevention	[Error Prevention] Avoid structured data sources with provider partitions	Power BI does not support provider (a.k.a. 'legacy') partitions which reference structured data sources. Partitions which reference structured data sources must use the M-language. Otherwise, 'provider' partitions must reference a 'provider' data source. This can be resolved by converting the structured data source into a provider data source (see 2nd reference link below). Reference: https://docs.microsoft.com/power-bi/admin/service-premium-connect-tools#data-source-declaration Reference: https://www.elegantbi.com/post/convertdatasources	2	1200
Formatting	[Formatting] First letter of objects must be capitalized		1	1200
Formatting	[Formatting] Percentages should be		2	1200

	formatted with thousands separators and 1 decimal			
Formatting	[Formatting] Whole numbers should be formatted with thousands separators and no decimals		2	1200
Formatting	[Formatting] Add data category for columns	Add Data Category property for appropriate columns. Reference: https://docs.microsoft.com/en-us/power-bi/transform-model/desktop-data-categorization	1	1200
Formatting	[Formatting] Provide format string for "Date" columns	Columns of type "DateTime" that have "Month" in their names should be formatted as "mm/dd/yyyy".	1	1200
Formatting	[Formatting] Provide format string for "Month" columns	Columns of type "DateTime" that have "Month" in their names should be formatted as "MMMM yyyy".	1	1200
Formatting	[Formatting] Format flag columns as Yes/No value strings	Flags must be properly formatted as Yes/No as this is easier to read than using 0/1 integer values.	1	1200
Formatting	[Formatting] Hide foreign keys	Foreign keys should always be hidden.	2	1200
Formatting	[Formatting] Relationship columns should be of integer data type	It is a best practice for relationship columns to be of integer data type. This applies not only to data warehousing but data modeling as well.	1	1200
Formatting	[Formatting] Hide fact table columns	It is a best practice to hide fact table columns that are used for aggregation in measures.	2	1200
Formatting	[Formatting] Do not summarize numeric columns	Numeric columns (integer, decimal, double) should have their SummarizeBy property set to "None" to avoid accidental summation in Power BI (create measures instead).	3	1200
Formatting	[Formatting] Objects should not start or end with a space	Objects should not start or end with a space	3	1200
Formatting	[Formatting] Mark primary keys	Set the 'Key' property to 'True' for primary key columns within the column properties.	1	1200
Formatting	[Formatting] Month (as a string) must be sorted	This rule highlights month columns which are strings and are not sorted. If left unsorted, they will sort alphabetically (i.e. April, August...). Make sure to sort such columns so that they sort properly (January, February, March...).	2	1200
Formatting	[Formatting] Provide format string for measures	Visible measures should have their format string property assigned	3	1200

Maintenance	[Maintenance] Visible objects with no description	Add descriptions to objects. These descriptions are shown on hover within the Field List in Power BI Desktop. Additionally, you can leverage these descriptions to create an automated data dictionary (see link below). Reference: https://www.elegantbi.com/post/datadictionary	1	1200
Maintenance	[Maintenance] Calculation groups with no calculation items	Calculation groups have no function unless they have calculation items.	2	1200
Maintenance	[Maintenance] Remove data sources not referenced by any partitions	Data sources which are not referenced by any partitions may be removed.	1	1200
Maintenance	[Maintenance] Remove unnecessary columns	Hidden columns that are not referenced by any DAX expressions, relationships, hierarchy levels or Sort By-properties should be removed.	2	1200
Maintenance	[Maintenance] Remove unnecessary measures	Hidden measures that are not referenced by any DAX expressions should be removed for maintainability	2	1200
Maintenance	[Maintenance] Remove roles with no members	May remove roles with no members.	1	1200
Maintenance	[Maintenance] Perspectives with no objects	Perspectives that contain no objects (tables) are most likely not necessary. In this rule, it is only necessary to check tables as adding a column/measure/hierarchy to a perspective also adds the table to the perspective. Additionally, tables in general covers calculated tables and calculation groups as well.	1	1200
Maintenance	[Maintenance] Fix referential integrity violations	This rule highlights relationships which have referential integrity violations. This indicates that there are values in the table on the 'from' side of the relationship which do not exist in the table on the 'to' side of the relationship. Referential integrity violations will also produce the 'blank' member value in slicers. It is recommended to fix these issues by ensuring that the 'to' table's primary key column has all the values in the 'from' table's foreign key column. Reference: https://blog.enterprisedna.co/vertipaq-analyzer-tutorial-relationships-referential-integrity/	2	1200

Maintenance	[Maintenance] Ensure tables have relationships	This rule highlights tables which are not connected to any other table in the model with a relationship.	1	1200
Naming Conventions	[Naming Conventions] Partition name should match table name for single partition tables	Tables with just one partition should match their table and partition names. Tables with more than one partition should have each partition name starting with the table name.	1	1200
Naming Conventions	[Naming Conventions] Object names must not contain special characters	Tabs, line breaks, etc.	2	1200
Performance	[Performance] Many-to-many relationships should be single-direction		2	1200
Performance	[Performance] Remove redundant columns in related tables		2	1200
Performance	[Performance] Measures using time intelligence and model is using Direct Query	At present, time intelligence functions are known to not perform as well when using Direct Query. If you are having performance issues, you may want to try alternative solutions such as adding columns in the fact table that show previous year or previous month data.	2	1200
Performance	[Performance] Remove auto-date table	Avoid using auto-date tables. Make sure to turn off auto-date table in the settings in Power BI Desktop. This will save memory resources. Reference: https://www.youtube.com/watch?v=xu3uDEHtCrg	2	1200
Performance	[Performance] Unpivot pivoted (month) data	Avoid using pivoted data in your tables. This rule checks specifically for pivoted data by month. Reference: https://www.elementbi.com/post/top10bestpractices	2	1200
Performance	[Performance] Check if bi-directional and many-to-many relationships are valid	Bi-directional and many-to-many relationships may cause performance degradation or even have unintended consequences. Make sure to check these specific relationships to ensure they are working as designed and are actually necessary. Reference: https://www.sqlbi.com/articles/bi-directional-relationships-and-ambiguity-in-dax/	1	1200
Performance	[Performance] Reduce usage of calculated	Calculated columns do not compress as well as data columns and may cause longer	2	1200

	columns that use the RELATED function	processing times. As such, calculated columns should be avoided if possible. One scenario where they may be easier to avoid is if they use the RELATED function. Reference: https://www.sqlbi.com/articles/storage-differences-between-calculated-columns-and-calculated-tables/		
Performance	[Performance] Reduce number of calculated columns	Calculated columns do not compress as well as data columns so they take up more memory. They also slow down processing times for both the table as well as process recalc. Offload calculated column logic to your data warehouse and turn these calculated columns into data columns. Reference: https://www.ele-gantbi.com/post/top10bestpractices	2	1200
Performance	[Performance] Avoid bi-directional relationships against high-cardinality columns	For best performance, it is recommended to avoid using bi-directional relationships against high-cardinality columns. In order to run this rule, you must first run the script shown here: https://www.ele-gantbi.com/post/vertipaqintabulareditor	2	1200
Performance	[Performance] Consider a star-schema instead of a snowflake architecture	Generally speaking, a star-schema is the optimal architecture for tabular models. That being the case, there are valid cases to use a snowflake approach. Please check your model and consider moving to a star-schema architecture. Reference: https://docs.microsoft.com/en-us/power-bi/guidance/star-schema	2	1200
Performance	[Performance] Model should have a date table	Generally speaking, models should generally have a date table. Models that do not have a date table generally are not taking advantage of features such as time intelligence or may not have a properly structured architecture.	2	1200
Performance	[Performance] Consider using aggregations if using Direct Query in Power BI	If using Direct Query in Power BI Premium, you may want to consider using aggregations in order to boost performance. Reference: https://docs.microsoft.com/en-us/power-bi/transform-model/desktop-aggregations	1	1200
Performance	[Performance] Reduce usage of long-length columns with high cardinality	It is best to avoid lengthy text columns. This is especially true if the column has many unique values. These types of columns can cause longer processing times, bloated model sizes, as well as slower user queries. Long length is defined as more than 100 characters.	2	1200

Performance	[Performance] Large tables should be partitioned	Large tables should be partitioned in order to optimize processing. In order for this rule to run properly, you must run the script shown here: https://www.ele-gantbi.com/post/vertipaqintabulareditor	2	1200
Performance	[Performance] Avoid excessive bi-directional or many-to-many relationships	Limit use of b-di and many-to-many relationships. This rule flags the model if more than 30% of relationships are bi-di or many-to-many. Reference: https://www.sqlbi.com/articles/bi-directional-relationships-and-ambiguity-in-dax/	2	1200
Performance	[Performance] Reduce usage of calculated tables	Migrate calculated table logic to your data warehouse. Reliance on calculated tables will lead to technical debt and potential misalignments if you have multiple models on your platform.	2	1200
Performance	[Performance] Minimize Power Query transformations	Minimize Power Query transformations in order to improve model processing performance. It is a best practice to offload these transformations to the data warehouse if possible. Also, please check whether query folding is occurring within your model. Please reference the article below for more information on query folding. Reference: https://docs.microsoft.com/en-us/power-query/power-query-folding	2	1200
Performance	[Performance] Do not use floating point data types	The "Double" floating point data type should be avoided, as it can result in unpredictable roundoff errors and decreased performance in certain scenarios. Use "Int64" or "Decimal" where appropriate (but note that "Decimal" is limited to 4 digits after the decimal sign).	2	1200
Performance	[Performance] Split date and time	This rule finds datetime columns that have values not at midnight. To maximize performance, the time element should be split from date element (or the time component should be rounded to midnight as this will reduce column cardinality). Reference: https://www.sqlbi.com/articles/separate-date-and-time-in-powerpivot-and-bism-tabular/	2	1200
Performance	[Performance] Date/calendar tables should be marked as a date table	This rule looks for tables that contain the words 'date' or 'calendar' as they should likely be marked as a date table. Reference: https://docs.microsoft.com/en-us/	2	1200

		us/power-bi/transform-model/desktop-date-tables		
Performance	[Performance] Set IsAvailableInMdx to false on non-attribute columns	To speed up processing time and conserve memory after processing, attribute hierarchies should not be built for columns that are never used for slicing by MDX clients. In other words, all hidden columns that are not used as a Sort By Column or referenced in user hierarchies should have their IsAvailableInMdx property set to false. Reference: https://blog.crossjoin.co.uk/2018/07/02/isavailableinmdx-ssas-tabular/	2	1200
Performance	[Performance] Limit row level security (RLS) logic	Try to simplify the DAX used for row level security. Usage of the functions within this rule can likely be offloaded to the upstream systems (data warehouse).	2	1200
Performance	[Performance] Check if dynamic row level security (RLS) is necessary	Usage of dynamic row level security (RLS) can add memory and performance overhead. Please research the pros/cons of using it. Reference: https://docs.microsoft.com/en-us/power-bi/admin/service-admin-rls	1	1200

Liite 3. Power BI Embedded hinnasto 16.2.2022

The total cost of Power BI Embedded depends on the node type chosen and the number of nodes deployed. Node types differ based on number of V-cores and RAM as outlined in the table below:

Node Type	Virtual Cores	Memory	Frontend / Backend Cores	Price
A1	1	3 GB RAM	0.5 / 0.5	€660.0709/month
A2	2	5 GB RAM	1 / 1	€1,314.8382/month
A3	4	10 GB RAM	2 / 2	€2,634.9144/month
A4	8	25 GB RAM	4 / 4	€5,275.1323/month
A5	16	50 GB RAM	8 / 8	€10,555.5028/month
A6	32	100 GB RAM	16 / 16	€21,116.6365/month